



Universidad
de Huelva

Universidad de Huelva
Facultad de Ingeniería Informática

Algoritmos de Búsqueda Multiarranque

Resultados y Análisis

Autor:

Matteo Sonaglioni

Año Académico 2025–2026

Curso de Modelos bioinspirados y heurísticas de búsqueda

Índice

1	Resultados	4
1.1	Configuración del Entorno de Pruebas	4
1.2	Funciones Objetivo y Criterio de Evaluación	4
1.2.1	Formulaciones Estándar	5
1.2.2	Formulaciones Avanzadas (Práctica 2 - Anexo)	5
1.2.3	El Árbitro Universal (Score Universal)	6
1.3	Tabla Global de Resultados	6
2	Gestión de Semillas y Evolución del Entorno Experimental	7
2.1	Actualización de Semillas (Práctica 1 vs. Práctica 2)	7
2.2	Impacto en los Resultados y Criterio de Comparación	7
3	Análisis	9
3.1	Algoritmo Greedy	9
3.2	Búsqueda Local (Primer Mejor)	10
3.3	Búsqueda Voraz Aleatoria Adaptativa (GRASP)	12
3.4	Búsqueda Local Iterativa (ILS)	13
3.5	Búsqueda Basada en Entornos Cambiantes (VNS)	15
4	Análisis de Caja Negra y Caja Blanca	17
4.1	Medidas de Evaluación de Caja Negra (Black-Box) - Caso 1	18
4.2	Medidas de Evaluación de Caja Blanca (White-Box) - Caso 1	19
4.2.1	Tasa de Diversificación Estructural (Overlap de Hamming)	19
4.2.2	Profundidad de Estancamiento (Stagnation Depth)	19
4.2.3	Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP	20
4.3	Medidas de Evaluación de Caja Negra (Black-Box) - Caso 2	21
4.4	Medidas de Evaluación de Caja Blanca (White-Box) - Caso 2	22
4.4.1	Tasa de Diversificación Estructural (Overlap de Hamming)	22
4.4.2	Profundidad de Estancamiento (Stagnation Depth)	22
4.4.3	Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP	23
4.5	Medidas de Evaluación de Caja Negra (Black-Box) - Caso 3	23
4.6	Medidas de Evaluación de Caja Blanca (White-Box) - Caso 3	25
4.6.1	Tasa de Diversificación Estructural (Overlap de Hamming)	25
4.6.2	Profundidad de Estancamiento (Stagnation Depth)	25
4.6.3	Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP	25

5	Observaciones y Análisis de Resultados	27
5.1	Análisis de Caja Negra: Robustez y Calidad Final	27
5.2	Análisis de Caja Blanca: Dinámica Interna y Diversificación	28
6	Conclusión Final	28

1 Resultados

A continuación, se presentan las configuraciones experimentales empleadas para cada uno de los algoritmos evaluados, junto con una tabla que recoge los resultados obtenidos.

1.1 Configuración del Entorno de Pruebas

Para garantizar una comparativa homogénea, se han mantenido los criterios de evaluación establecidos en la primera parte de la práctica: se han utilizado **5 semillas distintas** para el generador aleatorio y se han procesado de forma sistemática los **tres casos de estudio (Caso 1, Caso 2 y Caso 3)**.

Todos los algoritmos implementados en esta fase comparten como motor de explotación la **Búsqueda Local del Primer Mejor Vecino**, garantizando que las diferencias en el rendimiento se deban a las estrategias de exploración de cada metaheurística. Las configuraciones específicas han sido:

- **GRASP**: se ha configurado con una **Lista de Candidatos Restringida (RCL) de tamaño 3**, seleccionando estaciones mediante una heurística de potencial basada en la relación entre la necesidad de balanceo y la distancia Manhattan. En cada ejecución se generan **10 soluciones constructivas Greedy probabilísticas**, optimizadas individualmente.
- **ILS**: realiza un ciclo de **10 iteraciones de perturbación y mejora**. El operador de perturbación aplica una **mutación fuerte sobre sublistas cíclicas de tamaño fijo 4**, reasignando aleatoriamente los elementos. Se ha empleado el **Criterio del Mejor** como mecanismo de aceptación, aplicando siempre la mutación sobre la mejor solución global encontrada hasta el momento.
- **VNS**: utiliza **4 estructuras de entornos cambiantes** ($k_{max} = 4$) con un límite de **10 búsquedas locales por ejecución** ($bl_{max} = 10$). El tamaño de la sublista mutada varía dinámicamente según el nivel de entorno, escalando desde $n/6$ hasta $n/3$. Se sigue la lógica de volver al entorno $k = 1$ ante cualquier mejora y aumentar k en caso de estancamiento.

1.2 Funciones Objetivo y Criterio de Evaluación

Con el objetivo de evaluar el impacto de la formulación del *fitness* en el rendimiento de los algoritmos, se han implementado y comparado seis expresiones distintas

que combinan la distancia recorrida (kms) y la entropía del sistema (E). En este problema, la entropía máxima ideal es $E_{max} = 16.0$.

Las funciones analizadas se clasifican según su naturaleza y su penalización frente al desequilibrio:

1.2.1 Formulaciones Estándar

- **Ratio simple (`fobj_ratio`):** penaliza fuertemente la baja entropía mediante una relación lineal inversa.

$$f = \frac{kms}{E} \quad (1)$$

- **Suma ponderada (`fobj_suma_ponderada`):** combina ambos factores usando un peso α para la entropía (por defecto $\alpha = 2.0$).

$$f = kms - (\alpha \cdot E) \quad (2)$$

- **Ratio cuadrático (`fobj_ratio_cuadratico`):** penaliza de forma más severa la baja entropía al elevarla al cuadrado en el denominador.

$$f = \frac{kms}{E^2} \quad (3)$$

- **Exponencial decreciente (`fobj_exponencial`):** suaviza la penalización cuando la entropía es muy alta mediante un parámetro β (por defecto $\beta = 0.1$).

$$f = kms \cdot e^{-\beta \cdot E} \quad (4)$$

1.2.2 Formulaciones Avanzadas (Práctica 2 - Anexo)

Siguiendo las propuestas del anexo del problema, se han implementado dos fórmulas basadas en penalizaciones no lineales agresivas para priorizar estrictamente el inventario sobre la distancia:

- **Fórmula de Escalado Exponencial (`fobj_exponencial_priorizada`):** penaliza de forma explosiva si la entropía está lejos del máximo ideal. Utiliza el déficit absoluto para disparar el coste.

$$f = kms \cdot e^{\beta \cdot \max(0, E_{max} - E)} \quad (5)$$

- **Exponencial de Insatisfacción Relativa (`fobj_insatisfaccion_relativa`):** eleva la distancia a una potencia determinada por el déficit relativo. Si la en-

tropía es perfecta, el coste es puramente lineal (kms^1); si es pésima, el coste se acerca al modelo cuadrático (kms^2).

$$f = kms^{(1 + \frac{\max(0, E_{max} - E)}{E_{max}})} \quad (6)$$

1.2.3 El Árbitro Universal (Score Universal)

Dado que las metaheurísticas emplean estas distintas fórmulas internas para guiar la búsqueda y evadir óptimos locales, los valores resultantes de las Funciones Objetivo no son comparables directamente entre sí en magnitud.

Para garantizar una evaluación rigurosa, el análisis actúa como un “**Árbitro Universal**”: independientemente de la heurística matemática utilizada por el algoritmo, la solución final es juzgada y puntuada de forma estandarizada mediante la métrica base de *Ratio Simple*. Este enfoque permite una comparativa objetiva sobre la calidad física (distancia real y balanceo) de las rutas obtenidas.

1.3 Tabla Global de Resultados

La Tabla 1 ofrece un resumen exhaustivo y comparativo de los resultados experimentales, confrontando los algoritmos base de la primera fase (Greedy y Búsqueda Local del Primer Mejor) con las metaheurísticas multiarranque propuestas en esta segunda fase (GRASP, ILS y VNS).

Siguiendo la estructura requerida, para cada modelo se exponen las métricas obtenidas transversalmente en los tres casos de estudio. A continuación, se detalla el significado de los encabezados:

- **Modelo:** Algoritmo o técnica de optimización evaluada.
- **#Ev:** Número medio de evaluaciones de la función objetivo requeridas durante la ejecución (salvo para Greedy, que al ser determinista es 1).
- **F OBJ:** Valor estandarizado mediante el *Score Universal* (ratio simple) que actúa como árbitro para permitir una comparación justa entre algoritmos.
- **Kms:** Distancia total del recorrido de la mejor solución encontrada.
- **Entr:** Entropía alcanzada (grado de balanceo del sistema) de la mejor solución.

Tabella 1: Resultados Globales

Modelo	Caso 1				Caso 2				Caso 3			
	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr
Greedy	1.0	1.5485	23.68	15.2903	1.0	1.6087	23.77	14.7736	1.0	2.4834	23.24	9.3560
P.Mejor	333.6	1.5410	23.87	15.4872	311.7	1.5801	25.03	15.8404	377.0	2.1990	25.42	11.5598
GRASP	2030.3	1.3576	20.93	15.4210	2104.8	1.4377	22.69	15.7793	2609.8	2.0116	23.42	11.6435
ILS	1767.6	1.3585	20.93	15.4100	1843.2	1.4277	22.69	15.8888	2109.7	2.0116	23.42	11.6435
VNS	1238.7	1.3585	20.93	15.4100	1278.9	1.4277	22.69	15.8888	1553.0	2.0770	25.83	12.4367

2 Gestión de Semillas y Evolución del Entorno Experimental

Un aspecto crítico en el análisis de algoritmos estocásticos es la reproducibilidad y la sensibilidad a las condiciones iniciales. Siguiendo las recomendaciones docentes para esta segunda fase, se ha procedido a una actualización del conjunto de semillas del generador de números aleatorios.

2.1 Actualización de Semillas (Práctica 1 vs. Práctica 2)

Mientras que en la primera práctica se utilizaron valores simplificados para validar la lógica de los algoritmos, en la **Práctica 2** se han adoptado semillas de mayor entropía para poner a prueba la robustez de las nuevas metaheurísticas multiarranque (GRASP, ILS y VNS).

- **Semillas originales (P1):** [42, 123, 987, 555, 2024]. Estas semillas se emplearon para obtener los resultados base y los récords de la primera fase.
- **Semillas actualizadas (P2):** [382941, 4192853, 27849102, 391048576, 1842910337]. Este es el nuevo estándar utilizado para todas las ejecuciones reportadas en la presente memoria.

2.2 Impacto en los Resultados y Criterio de Comparación

Es importante notar que, debido a esta modificación, los resultados de los algoritmos de la Práctica 1 al ser ejecutados nuevamente en este entorno pueden presentar variaciones en sus métricas finales respecto a los informes previos.

Sin embargo, para los capítulos de **Análisis de Caja Negra** y **Análisis de Caja Blanca**, se ha mantenido el siguiente criterio de integridad:

- El valor de **Mejor Función Objetivo Conocida** ($FObj_{mejor_conocido}$) utilizado para el cálculo del Error Relativo Porcentual (RPD) corresponde al récord absoluto obtenido en la Práctica 1 con las semillas originales.
- Este enfoque garantiza que la comparativa de calidad de las nuevas metaheurísticas (GRASP, ILS, VNS) se realice frente al mejor rendimiento histórico alcanzado por el sistema, independientemente de la semilla actual utilizada para la exploración.

3 Análisis

Una vez expuestas la tabla global (Tabla 1) resumen en el capítulo anterior, en la presente sección se llevará a cabo una interpretación de las métricas obtenidas por cada algoritmo. El objetivo principal de este análisis no es únicamente identificar qué método ofrece el mejor resultado numérico, sino comprender el *porqué* de su comportamiento frente al problema de balanceo de la red de bicicletas.

3.1 Algoritmo Greedy

El algoritmo Greedy se utiliza como línea base de comparación. Al ser una técnica constructiva determinista, sus métricas no varían entre ejecuciones, proporcionando un punto de referencia estable para evaluar la ganancia obtenida por algoritmos más complejos.

Caso	Score (Ratio)	Kms	Entropía	Ev. Media	Ev. Mejor	T. Medio (s)	Semilla	Mejor FObj
Caso 1	1.5485	23.68	15.2903	1.0	1	0.0001	N/A	ratio
Caso 2	1.6087	23.77	14.7736	1.0	1	0.0001	N/A	ratio
Caso 3	2.4834	23.24	9.3560	1.0	1	0.0001	N/A	ratio

Tabella 2: Resultados obtenidos por el Algoritmo Greedy en los tres casos de prueba.

A partir de los datos tabulados (Tabla 2), se extraen las siguientes conclusiones sobre el comportamiento del Algoritmo Greedy:

- **Eficiencia Computacional y Determinismo:** el algoritmo exhibe un coste computacional ínfimo, resolviendo cualquier instancia en ~ 0.0001 segundos. Su naturaleza determinista implica que solo requiere una evaluación por caso, ya que ante los mismos datos siempre generará la misma ruta, independientemente de semillas aleatorias.
- **Miopía Estratégica:** el rendimiento espacial del algoritmo es ineficiente debido a su enfoque miope. Al seleccionar siempre la estación más cercana en cada paso, el algoritmo consume los nodos próximos rápidamente, viéndose obligado a realizar trayectos de retorno muy largos hacia la Estación 0 al final de la ruta. Esto mantiene la distancia total por encima de los 23 Kms en todos los casos, una cifra elevada considerando el tamaño de la red.
- **Limitación en el Balanceo:** los valores de Entropía obtenidos (15.29 y 14.77 para los Casos 1 y 2) demuestran que el algoritmo falla en su objetivo principal de equilibrar el sistema. Al no tener una visión global de la carga del camión

ni del estado de las estaciones futuras, el vehículo suele agotar su capacidad o vaciarse antes de llegar a estaciones críticas, resultando en un balanceo muy pobre tras finalizar la ruta.

- **Anomalía en el Caso 3:** aunque la Entropía reportada es menor (9.3560), esto no representa una mejora en la calidad del balanceo por parte del algoritmo, sino que es consecuencia directa de un dataset donde múltiples estaciones están inicializadas a cero. El desequilibrio real sigue siendo profundo, confirmado por el elevado Score Ratio de 2.4834.

3.2 Búsqueda Local (Primer Mejor)

A continuación, se analizan los resultados de la Búsqueda Local del Primer Mejor. Este algoritmo actúa como un motor de intensificación pura que, partiendo de una solución aleatoria, acepta el primer movimiento del vecindario que mejore la función objetivo actual.

La siguiente tabla resume las métricas físicas y computacionales obtenidas:

Caso	Score	Kms	Entropía	Ev. Media	Ev. Mejor	T. Medio (s)	Semilla	Mejor FObj
Caso 1	1.5410	23.87	15.4872	333.6	348	0.0061	4192853	ratio
Caso 2	1.5801	25.03	15.8404	311.7	358	0.0044	382941	insatisfac
Caso 3	2.1990	25.42	11.5598	377.0	382	0.0054	27849102	suma_ponde

Tabla 3: Resultados obtenidos por la Búsqueda Local (Primer Mejor) en los tres casos de prueba.




Figura 1: Evolución de la Función Objetivo, Distancia (Kms) y Entropía durante la ejecución de la Búsqueda Local del Primer Mejor para los tres casos.

Basándose en la tabla de resultados (Tabla 3) y en la observación de las gráficas de evolución (Figura 1), se establecen las siguientes conclusiones sobre su comportamiento:

- **Mejora frente a la Línea Base (Greedy):** la Búsqueda Local logra superar marginalmente los resultados del algoritmo Greedy en términos de *Score Universal* en todos los escenarios. Por ejemplo, en el *Caso 1*, el Score desciende de 1.5485 (Greedy) a 1.5410. Curiosamente, esto no se logra minimizando la distancia física (de hecho, los kilómetros suben a 23.87), sino alcanzando un grado de balanceo (Entropía) de 15.4872, demostrando cómo el algoritmo prioriza el inventario sobre el trayecto corto.
- **Estancamiento Prematuro en Óptimos Locales:** al analizar la convergencia, se evidencia la principal debilidad de las búsquedas locales simples. El algoritmo se detiene tras evaluar un promedio de ~ 310 a 380 soluciones, una cifra sumamente lejana al límite de seguridad de 3000 evaluaciones. Esto indica que el algoritmo desciende rápidamente hacia el fondo del "valle" topológico más cercano dictado por la semilla, pero carece de mecanismos de ruido para escapar de ese mínimo local.
- **Dependencia Estructural de la Semilla:** las gráficas de evolución (Figura 1) reflejan un patrón claro: una caída monótona muy pronunciada en las primeras 3 – 5 iteraciones de mejora, seguida de una línea plana e inamovible tan pronto como se agotan los movimientos que reportan un beneficio inmediato. La calidad final queda, por tanto, completamente anclada a la permutación aleatoria inicial.
- **Éxito de las Funciones Objetivo Avanzadas:** es un hallazgo metodológico crucial observar la elección de la función objetivo en el *Caso 2*. El algoritmo alcanzó su mejor rendimiento utilizando la función avanzada *insatisfac* (Exponencial de Insatisfacción Relativa). Tras una rigurosa depuración matemática en su implementación (asegurando la exponenciación en lugar de la suma lineal para penalizar la baja entropía), esta función demostró su valía: permitió alcanzar una Entropía casi perfecta (15.8404) penalizando severamente los Kms hasta que el sistema estuvo balanceado.
- **Viabilidad como Motor Interno:** aunque por sí solo resulta insuficiente para encontrar el óptimo global debido a su estancamiento (como demuestra el modesto Score de 2.1990 en el Caso 3), su extrema rapidez (~ 0.005 segundos por caso) y su rápido descenso topológico lo validan como un excelente

operador interno de intensificación para las metaheurísticas multiarranque de la siguiente fase (GRASP, ILS, VNS).

3.3 Búsqueda Voraz Aleatoria Adaptativa (GRASP)

El algoritmo GRASP introduce un enfoque multiarranque que combina la construcción iterativa de soluciones probabilísticas con una fase de intensificación pura. En cada una de sus 10 iteraciones, construye una ruta mediante una Lista de Candidatos Restringida (RCL) basada en una heurística de potencial (necesidad de bicicletas sobre distancia), para luego optimizarla utilizando la Búsqueda Local del Primer Mejor.

La siguiente tabla resume las métricas físicas y computacionales obtenidas:

Caso	Score (Ratio)	Kms	Entropía	Ev. Media	Ev. Mejor	T. Medio (s)	Semilla	Mejor FObj
Caso 1	1.3576	20.93	15.4210	2030.3	1893	0.0313	1842910337	ratio
Caso 2	1.4377	22.69	15.7793	2104.8	2329	0.0327	4192853	ratio
Caso 3	2.0116	23.42	11.6435	2609.8	2268	0.0407	382941	ratio

Tabella 4: Resultados obtenidos por el algoritmo GRASP en los tres casos de prueba.




Figura 2: Evolución de Caja Blanca de GRASP para los tres casos. Se observa la trayectoria dual con los saltos de exploración (solución actual en naranja) y las caídas de explotación (mejor solución en memoria en azul oscuro).

A partir de los datos tabulados (Tabla 4) y el análisis de la trayectoria de Caja Blanca (Figura 2), se extraen las siguientes conclusiones:

- **Robustez y Superioridad Global del Modelo:** GRASP se consolida como el algoritmo más competitivo y robusto evaluado hasta el momento. Logra abatir sustancialmente el coste espacial (reduciendo la distancia a 20.93 Kms en el *Caso 1*) sin sacrificar el balanceo del sistema (alcanzando una Entropía

de 15.4210). Mejora sistemáticamente todos los registros de la Búsqueda Local simple, demostrando el enorme valor de inyectar diversidad mediante el multiarranque.

- **Evolución Dual (Exploración vs. Explotación):** las gráficas de Caja Blanca revelan perfectamente el mecanismo de evasión de óptimos locales. Cada "pico" ascendente en la curva naranja representa el inicio de una nueva construcción Greedy probabilística (exploración), lo que empeora temporalmente el coste. Inmediatamente, la curva cae de forma drástica gracias a la Búsqueda Local (explotación). Este ciclo continuo permite que el algoritmo aterrice en cuencas de atracción más favorables, superando el estancamiento prematuro que paralizaba al "Primer Mejor".
- **Análisis de Diversificación y la RCL:** el uso de una Lista Restringida de tamaño 3 genera un nivel de solapamiento (*Overlap* de Hamming) medio-alto en las rutas iniciales. Esto indica que la heurística de construcción es lo bastante fuerte como para repetir prefijos lógicos atractivos de forma constante. Estudios empíricos paralelos con $RCL = 4$ y $RCL = 5$ demostraron que ampliar la lista no mejora la Función Objetivo final e incluso incrementa el ruido indeseado. Por tanto, $RCL = 3$ representa el equilibrio óptimo entre determinismo heurístico y aleatoriedad.
- **Inversión Computacional Rentable:** para alcanzar estos óptimos globales, el algoritmo incrementa significativamente su coste computacional frente a técnicas más simples, promediando entre 2030 y 2610 evaluaciones. No obstante, al delegar el peso del proceso a un operador local sumamente rápido, el tiempo total de ejecución se mantiene en un rango extremadamente bajo (rondando los $\sim 0.03 - 0.04$ segundos), justificando plenamente el aumento de llamadas a la función de coste a cambio de la excepcional fiabilidad de la solución.

3.4 Búsqueda Local Iterativa (ILS)

El algoritmo de Búsqueda Local Iterativa (ILS) aplica un enfoque basado en la perturbación controlada. Partiendo de una solución aleatoria optimizada inicialmente, el algoritmo realiza 10 iteraciones en las que aplica una "mutación fuerte" (desordenando una sublista cíclica de tamaño 4) sobre la mejor solución registrada, seguida inmediatamente de una Búsqueda Local del Primer Mejor. Este mecanismo busca escapar de los óptimos locales sin perder la estructura lógica ya construida.

La siguiente tabla resume las métricas físicas y computacionales obtenidas:

Caso	Score (Ratio)	Kms	Entropía	Ev. Media	Ev. Mejor	T. Medio (s)	Semilla	Mejor FObj
Caso 1	1.3585	20.93	15.4100	1767.6	1645	0.0252	27849102	ratio_cuad
Caso 2	1.4277	22.69	15.8888	1843.2	1536	0.0268	382941	suma_ponde
Caso 3	2.0116	23.42	11.6435	2109.7	1911	0.0335	4192853	ratio

Tabella 5: Resultados obtenidos por el algoritmo ILS en los tres casos de prueba.




Figura 3: Evolución de Caja Blanca de ILS para los tres casos. Los picos anaranjados representan las mutaciones fuertes (exploración), seguidas de caídas abruptas producto de la optimización local (explotación).

A partir de los datos tabulados (Tabla 5) y la observación detallada de las gráficas de trayectoria dual (Figura 3), se extraen las siguientes conclusiones:

- **Competitividad y Calidad de Solución:** ILS demuestra ser una metaheurística sumamente eficaz para este problema, logrando registros de altísima calidad. En el *Caso 3* logra alcanzar el récord absoluto absoluto (2.0116), y en el *Caso 1* se queda a escasas milésimas del óptimo global (1.3585). Además, en el *Caso 2*, minimiza drásticamente la entropía hasta dejarla casi en su máximo ideal (15.8888) obteniendo un excelente Score de 1.4277, lo que corrobora la efectividad del método de perturbación.
- **Dinámica de Perturbación en Caja Blanca:** la gráfica de evolución (Figura 3) ilustra a la perfección el comportamiento mecánico del ILS. La línea naranja (solución actual) muestra picos verticales muy pronunciados: son los instantes exactos en los que se aplica la mutación de la sublista de tamaño 4, "destruyendo" parte de la ruta y empeorando temporalmente la función objetivo. Sin embargo, estas perturbaciones son lo suficientemente fuertes como para sacar al algoritmo de la cuenca de atracción actual, permitiendo que la

posterior Búsqueda Local encuentre nuevos óptimos (reflejado en los descensos escalonados de la línea azul oscuro).

- **Profundidad de Estancamiento Controlada:** un factor crítico en el éxito de este algoritmo es que la Búsqueda Local interna no se atasca en mesetas inútiles. Al analizar las evaluaciones requeridas, cada fase de intensificación consume en promedio entre ~ 160 y 200 evaluaciones antes de detenerse al no encontrar un "Primer Mejor". Al no alcanzar profundidades de estancamiento extremas, el algoritmo puede aplicar sus mutaciones de forma ágil, explorando nuevas zonas del espacio de búsqueda sin desperdiciar iteraciones en el fondo de los valles.
- **Eficiencia Computacional:** a pesar de realizar múltiples reinicios desde posiciones mutadas, el número de evaluaciones medias se mantiene sumamente contenido (entre 1760 y 2110). Esto se traduce en tiempos de ejecución excepcionalmente bajos ($\sim 0.025 - 0.033$ segundos), haciendo de ILS una técnica muy rentable en términos de relación calidad-coste computacional.
- **Influencia de la Función Objetivo:** cabe destacar la gran adaptabilidad del algoritmo ante las distintas funciones de evaluación para evadir mínimos locales. Por ejemplo, en el *Caso 1* logró su mejor marca guiado por la métrica no lineal `ratio_cuad`, mientras que en el *Caso 2* destacó utilizando `suma_ponde` y en el *Caso 3* usando `ratio`. Esta flexibilidad confirma que la mutación de sublista se beneficia de guías matemáticas diferentes dependiendo de la topología particular de cada dataset.

3.5 Búsqueda Basada en Entornos Cambiantes (VNS)

El algoritmo VNS (Variable Neighborhood Search) basa su estrategia de exploración en el cambio sistemático de la estructura de vecindario. En lugar de aplicar una perturbación fija, el algoritmo escala la agresividad de la mutación (desde $k = 1$ hasta $k = 4$, aumentando el tamaño de la sublista alterada) cada vez que la Búsqueda Local se estanca, retornando al entorno más pequeño ($k = 1$) tan pronto como se logra una mejora.

La siguiente tabla resume las métricas físicas y computacionales obtenidas:

Caso	Score (Ratio)	Kms	Entropía	Ev. Media	Ev. Mejor	T. Medio (s)	Semilla	Mejor FObj
Caso 1	1.3585	20.93	15.4100	1238.7	1362	0.0186	27849102	ratio
Caso 2	1.4277	22.69	15.8888	1278.9	1162	0.0230	27849102	ratio_cuad
Caso 3	2.0770	25.83	12.4367	1553.0	1645	0.0260	1842910337	ratio_cuad

Tabella 6: Resultados obtenidos por el algoritmo VNS en los tres casos de prueba.




Figura 4: Evolución de Caja Blanca de VNS. Se aprecian las perturbaciones escalonadas generadas por los distintos tamaños de entorno (k) para escapar de los mínimos locales.

Basándose en la tabla de resultados (Tabla 6), las gráficas de evolución (Figura 4) y el estudio profundo de la dinámica interna, se extraen las siguientes conclusiones:

- **Rendimiento Competitivo pero Irregular:** el algoritmo VNS demuestra un buen nivel de optimización, logrando empatar el récord absoluto en el *Caso 2* (Score de 1.4277) con una Entropía casi perfecta. En el *Caso 1* también alcanza un nivel excepcional (1.3585), acercándose enormemente al óptimo. Sin embargo, en el *Caso 3* su rendimiento decrece (2.0770 frente al 2.0116 de GRASP/ILS). Esto sugiere que la perturbación por vecindarios fijos sufre en paisajes topológicos muy fragmentados (como el Caso 3, que tiene múltiples estaciones vacías).
- **Adaptación de la Función Objetivo:** es muy destacable que VNS lograra sus mejores marcas en los Casos 2 y 3 utilizando la función `ratio_cuad`. Al forzar penalizaciones cuadráticas, el algoritmo logró guiar la selección de sus vecindarios hacia configuraciones que maximizan el balanceo antes de intentar atajos físicos, demostrando la importancia de combinar un buen operador de vecindad con una función de coste exigente.

- **Alta Diversificación Estructural:** el análisis de solapamiento (Distancia de Hamming) revela que VNS es el algoritmo que produce las rutas iniciales más diversas de toda la comparativa. Al forzar cambios topológicos de magnitud creciente, el VNS asegura que la búsqueda se propague hacia áreas radicalmente distintas del espacio de soluciones.
- **Fallo Estructural en Redes Pequeñas (El problema de $k = 2$):** el análisis de la profundidad de estancamiento por nivel revela una deficiencia matemática en la jerarquía impuesta por la práctica ($s = n/6, n/5, n/4, n/3$). En un problema con rutas efectivas de $n = 16$ estaciones, los cálculos $\max(2, n/6)$ y $\max(2, n/5)$ colapsan al mismo valor entero ($s = 2$). En consecuencia, los entornos $k = 1$ y $k = 2$ son idénticos en la práctica. Esto provoca que el algoritmo desperdicie iteraciones (cero mejoras reales en $k = 2$ durante las pruebas) antes de poder escalar a $k = 3$, lo cual penaliza su eficiencia.
- **El “Sweet Spot” de Perturbación ($k = 3$):** los registros de ejecución evidencian que el entorno $k = 3$ (afectando a ~ 3 estaciones) es el principal motor de mejoras sustanciales, mientras que el nivel $k = 4$ resulta excesivamente destructivo para una red topológica tan pequeña. Se propone como futura mejora emplear una cuadrícula no lineal de entornos (por ejemplo, $s \in \{2, 3, 4, 6\}$) para evitar la redundancia matemática observada.
- **Eficiencia y Velocidad Controlada:** al tener un límite estricto de $bl_{max} = 10$ iteraciones de mejora local (frente al ciclo continuo condicionado del ILS), el VNS ejecuta un número menor de evaluaciones totales ($\sim 1230 - 1550$). Esto lo hace un algoritmo muy rápido en tiempo de CPU ($\sim 0.018 - 0.026$ segundos), aunque la parada por límite fijo puede interrumpir la exploración prematuramente en casos complejos.

4 Análisis de Caja Negra y Caja Blanca

La evaluación del rendimiento de las metaheurísticas multiarranque requiere una perspectiva dual. Por un lado, el enfoque de **Caja Negra** evalúa la robustez, calidad y dispersión del resultado final frente a múltiples ejecuciones estocásticas. Por otro, el enfoque de **Caja Blanca** examina el comportamiento interno, la trayectoria de búsqueda, la diversificación y los niveles de estancamiento.

A continuación, se presenta el análisis detallado para el **Caso 1**. Para garantizar la equidad comparativa, el Error Relativo Porcentual (RPD) se calcula tomando

como referencia el mejor valor histórico obtenido en la Práctica 1 para este caso ($FObj = 1.3665$, logrado por la Búsqueda Tabú).

4.1 Medidas de Evaluación de Caja Negra (Black-Box) - Caso 1

La siguiente tabla recoge la robustez matemática de los tres algoritmos tras 5 ejecuciones independientes:

Algoritmo	Media	Desviación (σ)	CV (%)	RPD (%)
GRASP	1.37	0.01	0.92	-0.65
ILS	1.49	0.09	6.08	0.00
VNS	1.43	0.07	4.74	-0.58

Tabella 7: Robustez matemática y Error Relativo Porcentual en el Caso 1.




Figura 5: Diagrama de Caja y Bigotes (Boxplot) comparando la dispersión de GRASP, ILS y VNS en 5 ejecuciones para el Caso 1.

Del análisis estadístico y visual se extraen las siguientes conclusiones fundamentales:

- **Mejora sobre el estado del arte (RPD negativo):** los valores de RPD negativos en GRASP (-0.65%) y VNS (-0.58%) indican empíricamente que

estas técnicas multiarranque han logrado superar el mejor registro absoluto de la Práctica 1. ILS, por su parte, logra igualar dicho récord (0.00%).

- **Supremacía de GRASP en Robustez:** como se aprecia claramente en el Boxplot (Figura 5), la caja de GRASP es sumamente compacta y se ubica en la parte más baja de la gráfica. Su Coeficiente de Variación es excepcional ($0.92\% < 5\%$), lo que demuestra que su fase constructiva probabilística es altamente estable y apenas se ve afectada por la semilla inicial.
- **Alta Dispersión en ILS y VNS:** la caja de ILS es la más elongada, evidenciando una fuerte varianza (CV del 6.08%) y dependencia estocástica. VNS logra alcanzar mínimos excelentes (su bigote inferior es casi tan bajo como el de GRASP), pero presenta valores atípicos superiores que estiran su media, restándole fiabilidad.

4.2 Medidas de Evaluación de Caja Blanca (White-Box) - Caso 1

Para comprender las razones detrás del rendimiento reportado en la Caja Negra, se procede a diseccionar el comportamiento interno de los algoritmos.

4.2.1 Tasa de Diversificación Estructural (Overlap de Hamming)

Esta métrica mide el grado de similitud entre las rutas generadas por las 5 semillas distintas, evaluando las primeras 4 posiciones (prefijo) del recorrido:

- **VNS (7.5% Overlap):** presenta la mayor diversificación estructural. Al cambiar constantemente el radio de los vecindarios (k), el VNS fuerza a la búsqueda a explorar topologías de ruta radicalmente distintas.
- **ILS (22.5% Overlap) y GRASP (25.0% Overlap):** presentan tasas de solapamiento moderadas. La heurística constructiva de GRASP tiende a favorecer ciertos inicios de ruta que son objetivamente mejores (alta demanda y corta distancia), lo que genera un cuarto de coincidencia estructural temprana.

4.2.2 Profundidad de Estancamiento (Stagnation Depth)

El análisis de las iteraciones internas infructuosas (donde la función de coste no mejora) revela el coste de exploración de las metaheurísticas:

- **Estancamiento Controlado en ILS:** la Búsqueda Local del ILS consume una media de 156.4 evaluaciones ($\sigma = 67.8$, máximo 316) antes de confirmar un óptimo local y desencadenar la mutación fuerte. Esto es altamente positivo: la explotación termina rápidamente, cediendo el control a la exploración y evitando desperdiciar ciclos en el fondo de los valles.
- **Fallo Estructural en la Jerarquía de VNS:** el desglose de mejoras por tamaño de entorno (k) arroja un fallo crítico. Mientras que el entorno más pequeño ($k = 1$) es el motor principal (aportando el 63.6% de los éxitos), el entorno $k = 2$ registra una tasa de éxito nula (0 mejoras en 12 intentos). Esto se debe a que, para redes pequeñas de 16 estaciones, los tamaños matemáticos $n/6$ y $n/5$ colapsan en el mismo valor de sublista ($s = 2$). En consecuencia, $k = 2$ resulta un paso redundante que gasta ciclos de CPU sin aportar nueva distorsión. El nivel $k = 3$ retoma la efectividad con un 27.3% de las mejoras.

4.2.3 Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP

Para verificar si el solapamiento del 25% en GRASP era indicio de un exceso de determinismo, se realizó un estudio paramétrico alterando el tamaño de la Lista de Candidatos Restringida (RCL):

RCL	Media FObj	Mejor FObj	σ	CV (%)	Overlap (%)
3	1.3682	1.3576	0.0126	0.92	25.0
4	1.3908	1.3766	0.0074	0.53	32.5
5	1.3613	1.3576	0.0042	0.31	40.0

Tabella 8: Estudio comparativo del parámetro RCL en GRASP (Caso 1).

Los resultados desafían la intuición estándar: aumentar la longitud de la lista de candidatos (de 3 a 5) **no reduce el solapamiento, sino que lo agrava** (pasando del 25% al 40%).

La explicación de este fenómeno radica en el esquema de selección por "ruleta de pesos". Al introducir candidatos subóptimos en la lista (estaciones muy lejanas o ya balanceadas), su probabilidad de selección es tan residual que el algoritmo termina eligiendo casi siempre a las 2 o 3 opciones dominantes iniciales, perdiendo el beneficio de la aleatoriedad uniforme. Por lo tanto, se concluye empíricamente que $RCL = 3$ es el punto de equilibrio ideal para este problema, maximizando la exploración útil sin degradar la calidad de la solución.

4.3 Medidas de Evaluación de Caja Negra (Black-Box) - Caso 2

Para el **Caso 2**, el análisis de Caja Negra se compara contra el mejor resultado histórico obtenido en la Práctica 1 ($FObj = 1.4377$, logrado mediante la Búsqueda Tabú).

La siguiente tabla recoge la robustez matemática tras 5 ejecuciones independientes:

Algoritmo	Media	Desviación (σ)	CV (%)	RPD (%)
GRASP	1.45	0.01	1.00	0.00
ILS	1.54	0.10	6.39	+0.08
VNS	1.56	0.09	5.99	0.00

Tabella 9: Robustez matemática y Error Relativo Porcentual en el Caso 2.




Figura 6: Diagrama de Caja y Bigotes comparando la dispersión de GRASP, ILS y VNS en 5 ejecuciones para el Caso 2.

Del análisis estadístico y visual del Boxplot (Figura 6) se derivan las siguientes observaciones:

- **Empate con el Estado del Arte ($RPD \approx 0\%$):** GRASP y VNS logran igualar milimétricamente el récord histórico de la Práctica 1 ($RPD 0.00\%$),

mientras que ILS se queda a una distancia matemáticamente insignificante (+0.08%). Esto demuestra que las metaheurísticas multiarranque son capaces de alcanzar el límite de optimización del problema en este escenario.

- **Consistencia Extrema de GRASP:** nuevamente, la caja de GRASP se muestra achatada y en el límite inferior de la gráfica. Su coeficiente de variación del 1.00% valida que su fase de construcción es altamente determinista en cuanto a la calidad del resultado final, blindando al algoritmo frente a ejecuciones aleatorias desfavorables.
- **Inestabilidad de VNS e ILS:** ambos algoritmos presentan cajas considerablemente alargadas, con coeficientes de variación en torno al 6%. El gran bigote superior de VNS y la caja expandida de ILS indican que, aunque pueden alcanzar el óptimo, frecuentemente se quedan atrapados en cuencas de atracción subóptimas dependiendo de la permutación inicial.

4.4 Medidas de Evaluación de Caja Blanca (White-Box) - Caso 2

4.4.1 Tasa de Diversificación Estructural (Overlap de Hamming)

El solapamiento en las 4 primeras posiciones del recorrido ofrece resultados contrastantes:

- **ILS y VNS (12.5% Overlap):** ambos algoritmos presentan una excelente diversificación, asegurando que las distintas ejecuciones exploren vecindarios estructuralmente disjuntos desde el inicio.
- **GRASP (35.0% Overlap):** el solapamiento aumenta respecto al Caso 1. El peso de la heurística sesga probabilísticamente la elección de los primeros nodos, sacrificando diversidad en favor de prefijos de alta calidad garantizada.

4.4.2 Profundidad de Estancamiento (Stagnation Depth)

- **ILS:** La búsqueda local se trunca tras una media de 165.7 evaluaciones ($\sigma = 77.0$). Sigue demostrando cortes rápidos que habilitan el ciclo de mutación ágilmente.
- **VNS (Confirmación del fallo en $k = 2$):** los datos del Caso 2 corroboran el patrón descubierto en el Caso 1. El entorno $k = 1$ aporta el 77.8% de los éxitos, y el $k = 3$ el 22.2%. Por su parte, $k = 2$ **registra nuevamente 0**

mejoras en 11 intentos. Esto solidifica la conclusión de que en redes de este tamaño, el colapso matemático hace que los entornos 1 y 2 actúen sobre la misma cantidad de nodos, convirtiendo a $k = 2$ en una etapa completamente redundante que penaliza la convergencia. Además, $k = 4$ tampoco reporta éxitos (0 de 8), demostrando ser demasiado destructivo.

4.4.3 Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP

El análisis paramétrico de la RCL en este escenario arroja un resultado sumamente revelador:

RCL	Media FObj	Mejor FObj	σ	CV (%)	Overlap (%)
3	1.4491	1.4377	0.0144	1.00	35.0
4	1.4619	1.4603	0.0033	0.23	60.0
5	1.4531	1.4377	0.0145	1.00	30.0

Tabella 10: Estudio comparativo del parámetro RCL en GRASP (Caso 2).

Aumentar la lista a $RCL = 4$ genera una **anomalía estadística**: la Función Objetivo empeora (1.4603) y la Tasa de Overlap se dispara a un inaceptable 60.0%.

Este comportamiento contraintuitivo confirma que incluir más candidatos debilita la calidad de la exploración: al asignar pesos muy bajos a la cuarta opción, el motor aleatorio rara vez la elige, pero el simple hecho de alterar las proporciones de la ruleta matemática provoca que el algoritmo colapse repetidamente hacia la opción de mayor peso. Se reafirma así que $RCL = 3$ ofrece el mejor desempeño general.

4.5 Medidas de Evaluación de Caja Negra (Black-Box) - Caso 3

El **Caso 3** presenta un desafío topológico particular, ya que casi la mitad de la red (7 estaciones) comienza completamente vacía, lo que genera un paisaje de soluciones más fragmentado. Para este caso, el rendimiento se contrasta con el récord de la Práctica 1 ($FObj = 2.0116$, alcanzado por el Enfriamiento Simulado).

Algoritmo	Media	Desviación (σ)	CV (%)	RPD (%)
GRASP	2.09	0.06	3.09	0.00
ILS	2.18	0.13	5.99	0.00
VNS	2.21	0.09	4.23	+4.13

Tabella 11: Robustez matemática y Error Relativo Porcentual en el Caso 3.




Figura 7: Diagrama de Caja y Bigotes comparando la dispersión de GRASP, ILS y VNS en 5 ejecuciones independientes para el Caso 3.

Del análisis estadístico de la Tabla 11 y el Boxplot (Figura 7) se extraen las siguientes conclusiones:

- **Éxito de GRASP e ILS:** ambas metaheurísticas logran alcanzar el récord histórico (RPD 0.00%), demostrando su capacidad para navegar en espacios de alta dificultad topológica. GRASP vuelve a dominar en robustez, exhibiendo la media más baja (2.09) y una dispersión sumamente controlada (CV del 3.09%).
- **Fracaso Relativo de VNS:** este es el único escenario donde una metaheurística de la Práctica 2 no logra igualar a las de la Práctica 1. VNS se queda a un +4.13% del óptimo global. Al haber tantas estaciones vacías, la mutación de vecindarios fijos introduce demasiado ruido no constructivo, impidiendo que la búsqueda local subsiguiente converja hacia el mínimo absoluto.
- **Varianza de ILS:** aunque ILS alcanza el récord, su diagrama de caja muestra una enorme elongación, con el bigote superior rozando el 2.35. Esto confirma que su fiabilidad en este caso es altamente dependiente de la semilla aleatoria inicial.

4.6 Medidas de Evaluación de Caja Blanca (White-Box) - Caso 3

4.6.1 Tasa de Diversificación Estructural (Overlap de Hamming)

- **VNS (7.5% Overlap)**: sigue garantizando una diversificación casi total en las rutas iniciales, corroborando que su fallo en la Caja Negra no se debe a la falta de exploración, sino a una exploración ineficiente o demasiado destructiva.
- **GRASP (20.0%) e ILS (22.5%)**: mantienen tasas de solapamiento moderadas, confirmando un buen balance estructural entre componentes deterministas y estocásticos.

4.6.2 Profundidad de Estancamiento (Stagnation Depth)

- **ILS**: el coste de validación de la Búsqueda Local asciende ligeramente a 177.8 evaluaciones medias por ciclo (máximo 433). Este incremento es esperable: ante la presencia de tantas estaciones vacías, el algoritmo necesita evaluar más combinaciones antes de confirmar la ausencia de movimientos de mejora. Aun así, sigue garantizando cortes ágiles.
- **VNS (Consistencia del patrón)**: el entorno $k = 1$ aporta el 64.3% de las mejoras y $k = 3$ el 21.4%. Curiosamente, en este caso $k = 2$ logra una (1) única mejora tras 11 intentos (tasa de éxito del 9.1%). Si bien no es nulo como en los Casos 1 y 2, un aporte del 7.1% al total de mejoras corrobora abrumadoramente la hipótesis de que la definición matemática de la práctica ($s = n/6, n/5$) colapsa en redes de este tamaño, haciendo que la transición entre $k = 1$ y $k = 2$ sea estructuralmente redundante.

4.6.3 Sensibilidad y Ajuste de la Lista Restringida (RCL) en GRASP

El análisis de sensibilidad de la RCL en un entorno con 7 estaciones vacías demuestra los límites de relajar la heurística:

RCL	Media FObj	Mejor FObj	σ	CV (%)	Overlap (%)
3	2.0926	2.0116	0.0648	3.09	20.0
4	2.0863	2.0116	0.0643	3.08	17.5
5	2.1275	2.0563	0.0511	2.40	20.0

Tabella 12: Estudio comparativo del parámetro RCL en GRASP (Caso 3).

Aunque ampliar la lista a $RCL = 4$ mantiene el mejor récord y mejora marginalmente la media general (2.0863), forzar la lista a $RCL = 5$ degrada drásticamente la calidad de la mejor solución encontrada (2.0563).

Incluir hasta 5 opciones en un escenario donde muchas estaciones no requieren balanceo (están vacías y el camión quizás no tiene inventario para suplirlas) inyecta opciones "basura" en la ruleta de selección constructiva. Queda demostrado que $RCL = 3$ es la opción más segura y predecible, al limitar las decisiones iniciales del GRASP únicamente a los nodos con mayor necesidad real de intervención.

5 Observaciones y Análisis de Resultados

Tras completar la fase de experimentación avanzada y aplicar el principio del “**Árbitro Universal**”, se presentan las observaciones derivadas del comportamiento de las metaheurísticas multiarranque (GRASP, ILS y VNS) en comparación con los resultados base de la Práctica 1.

5.1 Análisis de Caja Negra: Robustez y Calidad Final

El estudio estadístico de las 5 ejecuciones independientes para cada algoritmo ha revelado diferencias críticas en la fiabilidad de los métodos bajo el nuevo conjunto de semillas:

- **Supremacía de GRASP en Estabilidad ($CV < 5\%$):** En los tres casos de estudio, el algoritmo GRASP se consolida como el más robusto. Su Coeficiente de Variación (CV) se mantiene sistemáticamente entre el 0.92% y el 3.09%, lo que indica una dispersión mínima. Visualmente, en los diagramas de caja (*Boxplots*), esto se traduce en cajas sumamente compactas situadas en los rangos inferiores de coste, demostrando que su fase constructiva probabilística es altamente insensible a la variabilidad de las semillas.
- **Mejora sobre los Récorde de la Práctica 1 (RPD Negativo):** El análisis del Error Relativo Porcentual (RPD) confirma que las técnicas multiarranque han logrado batir el estado del arte previo. En el **Caso 1**, GRASP alcanza un Score de 1.3576 ($RPD = -0.65\%$) y VNS un 1.3585 ($RPD = -0.58\%$), superando ambos a la Búsqueda Tabú. En los **Casos 2 y 3**, los algoritmos han logrado igualar el récord histórico conocido ($RPD = 0.00\%$), destacando el empate técnico entre ILS y VNS en el Caso 2 (1.4277) y entre GRASP e ILS en el Caso 3 (2.0116).
- **Inestabilidad Relativa en Paisajes Fragmentados:** A diferencia de GRASP, ILS y VNS muestran cajas más elongadas en los Boxplots ($CV \sim 4\% - 6\%$). En el **Caso 3**, el escenario con mayor número de estaciones vacías, VNS es el único que no logra igualar el récord (2.0770 vs 2.0116), con un RPD de +4.13%. Esto sugiere que el cambio de entorno fijo del VNS es más sensible a topologías de red fragmentadas que el multiarranque puro de GRASP.

5.2 Análisis de Caja Blanca: Dinámica Interna y Diversificación

El análisis de los registros internos y las trayectorias de búsqueda permite explicar los resultados físicos obtenidos:

- **Tasa de Diversificación (Hamming):** Se comprueba que **VNS es el algoritmo más diversificado estructuralmente**, con un solapamiento (*Overlap*) de apenas el 7.5% entre rutas iniciales. Esto se debe a su jerarquía de entornos cambiantes. Por el contrario, GRASP presenta un solapamiento superior (20% – 35%), lo que indica que su heurística de potencial es muy directiva y tiende a favorecer ciertos prefijos lógicos de ruta que garantizan un buen balanceo inicial.
- **Fallo Estructural en VNS ($k = 2$):** Se confirma el hallazgo de una redundancia matemática en la jerarquía de entornos. En redes de este tamaño ($n = 16$ estaciones), los niveles $k = 1$ ($\max(2, n/6)$) y $k = 2$ ($\max(2, n/5)$) colapsan frecuentemente en el mismo tamaño de sublista ($s = 2$). Los datos de ejecución revelan que $k = 2$ registra una tasa de éxito casi nula (solo 1 mejora en 11 intentos en el Caso 3), actuando como un paso redundante que penaliza la eficiencia computacional frente al nivel $k = 3$, que es el motor real de mejoras sustanciales.
- **Justificación Empírica de $RCL=3$:** El estudio de sensibilidad en GRASP ratifica que el valor por defecto ($RCL = 3$) es el *sweet spot*. Aumentar la lista a $RCL = 5$ inyecta opciones de bajo potencial que degradan la calidad del mejor resultado (2.0563 en el Caso 3) e incluso aumentan el solapamiento, ya que la ruleta ponderada termina colapsando siempre hacia las pocas opciones dominantes.

6 Conclusión Final

Tras someter a los algoritmos multiarranque a un análisis riguroso de Caja Negra y Caja Blanca con los nuevos resultados experimentales, se establecen las siguientes conclusiones:

- **Superioridad de la Exploración Múltiple:** Se demuestra que la combinación de fases de exploración (construcción aleatoria o mutación) con explotación (Búsqueda Local) es la estrategia definitiva para evitar el atrapamiento en óptimos locales que limitaba a las técnicas de la Práctica 1.

- **Ganador Absoluto por Fiabilidad (GRASP):** Por su capacidad para superar los mejores récords conocidos en el Caso 1, igualarlos en el Caso 3 y, sobre todo, por su extraordinaria robustez estadística (mínima varianza), el algoritmo **GRASP** se declara como el más eficiente para este problema de logística urbana.
- **Potencial del ILS:** El ILS se posiciona como una alternativa de gran calidad, logrando igualar los mejores Scores en todos los escenarios con un coste computacional intermedio, demostrando que una perturbación cíclica de sublista es suficiente para navegar por el espacio de soluciones sin necesidad de jerarquías complejas.

En definitiva, esta práctica confirma que el éxito en la optimización de redes de transporte no depende solo del algoritmo, sino de la inteligencia con la que se inyecta diversidad en el sistema para navegar por un espacio de búsqueda altamente rugoso y fragmentado.