



Universidad
de Huelva

Universidad de Huelva
Facultad de Ingeniería Informática

Algoritmos Genéticos

Resultados y Análisis

Autor:

Matteo Sonaglioni

Año Académico 2025-2026

Curso de Modelos bioinspirados y heurísticas de búsqueda

Índice

1	Resultados	4
1.1	Decisiones de Diseño y Justificación Algorítmica	4
1.1.1	Distancia de Hamming Adaptada a Secuencias	5
1.2	Resultados Globales	5
2	Análisis de Resultados	7
2.1	Línea Base: Algoritmo Greedy	7
2.2	Línea Base: Búsqueda Local (Primer Mejor)	8
2.3	Algoritmo Evolutivo: Algoritmo Genético Básico	9
2.3.1	Resultados Parciales y Evaluación de Robustez	11
2.3.2	Análisis de los Resultados Parciales (AG Básico)	12
2.4	Algoritmo Evolutivo: CHC (Cross-Generational Elitist Selection, He- terogeneous Recombination and Cataclysmic Mutation)	12
2.4.1	Resultados Parciales y Evaluación de Robustez	14
2.4.2	Análisis de los Resultados Parciales (CHC)	14
2.5	Algoritmo Evolutivo: Multimodal (Clearing)	15
2.5.1	Resultados Parciales y Evaluación de Robustez	17
2.5.2	Análisis de los Resultados Parciales (AG Multimodal)	17
2.6	Caso 1 - Análisis de Caja Negra: Robustez y Error Relativo	18
2.7	Caso 1 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos	20
2.7.1	Diversificación Estructural: Posición vs. Arcos	20
2.7.2	Convergencia y Reinicios del Algoritmo CHC	21
2.7.3	Dinámica de Nichos en el Algoritmo Multimodal (<i>Clearing</i>)	22
2.8	Caso 2 - Análisis de Caja Negra: Robustez y Error Relativo	23
2.9	Caso 2 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos	25
2.9.1	Diversificación Estructural: Posición vs. Arcos	25
2.9.2	Convergencia y Reinicios del Algoritmo CHC (Caso 2)	26
2.9.3	Dinámica de Nichos en el Algoritmo Multimodal (Caso 2)	27
2.10	Caso 3 - Análisis de Caja Negra: Robustez y Error Relativo	28
2.11	Caso 3 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos	29
2.11.1	Diversificación Estructural: Posición vs. Arcos	30
2.11.2	Convergencia y Reinicios del Algoritmo CHC (Caso 3)	30

2.11.3	Dinámica de Nichos en el Algoritmo Multimodal (Caso 3)	32
2.12	Estudio Paramétrico: Justificación de Decisiones de Diseño	32
2.12.1	Algoritmo Genético Multimodal (Clearing): Radio y Capacidad de Nicho	33
2.12.2	Algoritmo Genético CHC: Umbral Inicial de Incesto	34
2.12.3	Algoritmo Genético Básico: Análisis Paramétrico	35
2.13	Análisis Visual de Nichos (Caso 1)	37
3	Observaciones y Conclusiones	39
3.1	Síntesis del Rendimiento Algorítmico	39
3.2	Justificación de la Métrica Estructural	39
3.3	Conclusión Final	40

1 Resultados

El presente estudio aborda la optimización y el balanceo de una red de estaciones de bicicletas mediante el diseño y la implementación de algoritmos evolutivos. Específicamente, se ha evaluado el rendimiento de un Algoritmo Genético (AG) Básico, el algoritmo CHC y un AG Multimodal basado en el paradigma de *Clearing*. Con el objetivo de establecer una línea base de rendimiento, los resultados poblacionales se contrastan de forma sistemática con los métodos de trayectoria previamente desarrollados: el algoritmo constructivo *Greedy* y la Búsqueda Local del Primer Mejor.

Todas las experimentaciones evolutivas se han llevado a cabo bajo un marco de evaluación estricto, empleando una población de 30 individuos y un presupuesto computacional máximo de 3000 evaluaciones por ejecución, garantizando así la equidad en la comparativa de esfuerzo computacional.

1.1 Decisiones de Diseño y Justificación Algorítmica

El rendimiento de las metaheurísticas poblacionales depende críticamente de la parametrización y de la idoneidad de los operadores genéticos respecto a la topología del problema. Tras un análisis paramétrico exhaustivo, se han consolidado las siguientes decisiones de diseño:

- **Modelo Poblacional y Elitismo:** Se ha adoptado un modelo *Generacional* complementado con un elitismo estricto de un individuo ($E = 1$). Esta configuración previene la pérdida estocástica de la mejor solución encontrada a lo largo de las generaciones, garantizando una convergencia monótona más estable que la observada en modelos estacionarios puros.
- **Operadores Genéticos de Recombinación y Mutación:** Para el operador de recombinación en el AG Básico y Multimodal, se ha implementado el Cruce Basado en Orden circular (OX) con una tasa de aplicación del 90%. La variante circular es fundamental para este problema, ya que preserva el orden relativo de los genes y, en consecuencia, la topología de los arcos del progenitor, de los cuales depende intrínsecamente la función de coste. La mutación se rige por un operador de inversión de segmento (*2-opt*), perturbando entre el 5% y el 10% del cromosoma. Para preservar la explotación, la mutación se aplica exclusivamente cuando no se produce recombinación, actuando como un mecanismo de inyección de diversidad controlada.

- **Mecanismo de Selección:** Se ha optado por una selección por Torneo con un tamaño $K = 3$ (equivalente al 10% de la población). Esta magnitud ejerce una presión selectiva equilibrada: es suficientemente alta para guiar la búsqueda hacia cuencas de atracción prometedoras, pero lo bastante contenida para evitar una convergencia prematura.
- **Recombinación HUX y Prevención de Incesto en CHC:** Dado que el algoritmo CHC clásico opera sobre codificación binaria, se ha adaptado el operador HUX para codificación de orden mediante transposiciones, asegurando la viabilidad de las permutaciones resultantes. El umbral inicial de incesto se establece empíricamente en $L/4$, reduciéndose progresivamente frente al estancamiento hasta desencadenar un reinicio poblacional basado en el mejor individuo.
- **Paradigma Multimodal (*Clearing*):** Frente a alternativas como *Shared Fitness* o los métodos secuenciales, se ha implementado el *Clearing* con un radio de nicho de $L/4$ y una capacidad de preservación $\kappa = 1$. Este paradigma permite sostener simultáneamente múltiples óptimos locales en el frente de búsqueda de manera explícita, facilitando un análisis de Caja Blanca mucho más nítido sobre la distribución de nichos por generación.

1.1.1 Distancia de Hamming Adaptada a Secuencias

Un pilar fundamental en la implementación del algoritmo CHC y del *Clearing* es la métrica de similitud entre cromosomas. La Distancia de Hamming clásica penaliza diferencias posicionales absolutas, lo cual resulta matemáticamente falaz en problemas de rutas: dos secuencias que describen exactamente el mismo recorrido pero con un desfase cíclico de un índice mostrarían una divergencia máxima bajo el paradigma clásico, a pesar de compartir el mismo coste y estructura física.

Para solventar esta divergencia topológica, se ha implementado una *Distancia de Hamming orientada a arcos*. Esta métrica cuantifica el número de transiciones (pares de nodos consecutivos) presentes en un cromosoma pero ausentes en otro. Al convertir los arcos en la verdadera unidad de similitud, tanto el umbral de incesto del CHC como el radio de especiación del Multimodal operan sobre la misma realidad estructural que define la Función Objetivo.

1.2 Resultados Globales

La Tabla 1 recoge el **mejor resultado individual** alcanzado por cada algoritmo a lo largo de todas las ejecuciones. Para esta comparativa global, se ha explota-

do la ventaja del multiarranque algorítmico, realizando un barrido sobre distintas formulaciones de la función objetivo y preservando la solución de mayor calidad matemática. Todas las comparativas directas se referencian empleando la métrica estándar del *Score Universal* (kilómetros penalizados por entropía).

Modelo	Caso 1				Caso 2				Caso 3			
	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr
Greedy	1	1.5485	23.68	15.2903	1	1.6087	23.77	14.7736	1	2.4834	23.24	9.3560
P.Mejor	333.6	1.5410	23.87	15.4872	311.7	1.5801	25.03	15.8404	377.0	2.1990	25.42	11.5598
Básico	3000	1.3591	20.93	15.4031	3000	1.4277	22.69	15.8888	3000	2.0817	24.39	11.7142
CHC	3000	1.3576	20.93	15.4210	3001	1.4277	22.69	15.8888	3002	2.0116	23.42	11.6435
Multimodal	3000	1.3576	20.93	15.4210	3000	1.4377	22.69	15.7793	3000	2.0268	23.74	11.7122

Tabella 1: Resultados Globales. Muestra el mejor valor histórico obtenido por cada algoritmo empleando el barrido de funciones objetivo. Se resalta en negrita el resultado óptimo por caso.

A simple vista, resalta la superioridad aplastante de los métodos evolutivos frente a las técnicas basadas en trayectorias simples. En los Casos 1 y 2, los algoritmos genéticos han logrado batir el estado del arte previamente establecido en las prácticas anteriores, alcanzando mesetas óptimas inéditas. Resulta especialmente notable el rendimiento del algoritmo CHC, que domina la tabla logrando el óptimo absoluto en los tres escenarios evaluados. El incremento en el número de evaluaciones (de aproximadamente 350 en la Búsqueda Local a 3000 en los evolutivos) queda matemáticamente justificado por una reducción drástica en la función objetivo, demostrando que la exploración cooperativa del espacio de soluciones es indispensable en redes de alta asimetría.

2 Análisis de Resultados

En esta sección se desglosa el comportamiento individual y comparativo de los distintos algoritmos evaluados. El análisis se fundamenta tanto en métricas de Caja Negra (robustez, error relativo, calidad final) como en métricas de Caja Blanca (convergencia, diversidad genética y distribución de nichos), con el fin de comprender no solo la calidad de las soluciones, sino también la dinámica de exploración del espacio de búsqueda.

2.1 Línea Base: Algoritmo Greedy

El algoritmo heurístico constructivo (*Greedy*) actúa como el límite inferior de esfuerzo computacional y establece la primera línea base de calidad. Al ser un método puramente determinista, no requiere inicialización estocástica (semilla) y converge en una única evaluación secuencial.

Escenario	Score (Ratio)	Kms	Entropía	Evaluaciones
Caso 1	1.5485	23.68	15.2903	1.0
Caso 2	1.6087	23.77	14.7736	1.0
Caso 3	2.4834	23.24	9.3560	1.0

Tabla 2: Rendimiento del Algoritmo Greedy en los tres escenarios de prueba. La función de evaluación empleada es el ratio puro (Kms/Entropía).

Del análisis de la Tabla 2, se extraen las siguientes implicaciones estructurales:

- **Eficiencia Computacional vs. Calidad Óptima:** El método garantiza una inmediatez absoluta (requiriendo 1.0 evaluación con un tiempo de CPU marginal de ≈ 0.0001 s). No obstante, esta total falta de exploración combinatoria condena al algoritmo a quedar atrapado en el primer mínimo local dictado por su heurística miope, devolviendo las soluciones de peor calidad de toda la comparativa.
- **Sensibilidad ante Topologías Asimétricas (Caso 3):** Se observa una notable degradación del rendimiento en el Caso 3. Mientras que en los Casos 1 y 2 el algoritmo logra mantener un balance distributivo razonable (entropías cercanas a 15), en el Caso 3 sufre un colapso operativo. Al enfrentarse a una red altamente asimétrica con múltiples estaciones vacías, las decisiones locales irrevocables del algoritmo generan rutas ineficientes que hunden la entropía

final a 9.3560, disparando el coste de la función objetivo hasta 2.4834. Esto demuestra la incapacidad de un enfoque constructivo simple para lidiar con paisajes de búsqueda fragmentados.

2.2 Línea Base: Búsqueda Local (Primer Mejor)

Como segunda métrica de referencia, se evalúa el algoritmo de Búsqueda Local basado en la estrategia del Primer Mejor (*First Best*). A diferencia del enfoque constructivo miópico, esta técnica fundamentada en trayectorias explora el vecindario de una solución inicial, aplicando de forma iterativa el primer movimiento de intercambio (*swap*) que garantice una mejora estricta en la función de *fitness*, hasta alcanzar un punto de convergencia.

Escenario	Score (Ratio)	Kms	Entropía	Ev. Media
Caso 1	1.5410	23.87	15.4872	333.6
Caso 2	1.5801	25.03	15.8404	311.7
Caso 3	2.1990	25.42	11.5598	377.0

Tabella 3: Rendimiento de la Búsqueda Local (Primer Mejor). Se reporta el coste computacional en términos de evaluaciones medias requeridas para alcanzar el estancamiento.




Figura 1: Evolución de Caja Blanca para la Búsqueda Local (Primer Mejor) en los tres casos de estudio. Se representa la convergencia de la Función Objetivo junto con la dinámica subyacente de los Kilómetros y la Entropía.

A partir de los resultados numéricos de la Tabla 3 y el análisis visual de las trayectorias (Figura 1), se derivan las siguientes conclusiones:

- **Mejora Relativa y Estancamiento Local:** La Búsqueda Local logra superar consistentemente al algoritmo *Greedy*, destacando una corrección significa-

tiva de la ineficiencia estructural en el Caso 3 (reduciendo el coste de 2.4834 a 2.1990). Sin embargo, debido a la ausencia intrínseca de mecanismos para tolerar empeoramientos temporales o inyectar diversidad, la trayectoria de búsqueda converge prematuramente hacia mínimos locales subóptimos, quedando muy lejos de los óptimos globales alcanzados por los modelos evolutivos.

- **Equilibrio entre Coste y Beneficio Computacional:** La convergencia del algoritmo se produce en un rango estrecho y predecible de 311 a 377 evaluaciones promedio. Este coste computacional representa un incremento de varios órdenes de magnitud respecto al *Greedy*, pero equivale a apenas una décima parte del presupuesto asignado a los algoritmos genéticos (3000 evaluaciones). Por consiguiente, se define como un método de explotación rápido, adecuado para refinar soluciones bajo restricciones estrictas de tiempo, pero carente de la capacidad de exploración profunda.
- **Dinámica de Convergencia (Caja Blanca):** Las gráficas revelan una caída pronunciada de la Función Objetivo en las primeras iteraciones de la ejecución, impulsada fundamentalmente por una drástica optimización de los kilómetros recorridos. En las redes simétricas (Casos 1 y 2), el algoritmo logra mantener la entropía en niveles notablemente altos y estables. Por el contrario, en el Caso 3, la topología fragmentada fuerza al sistema a sacrificar la entropía (cayendo por debajo de 12) para minimizar el desplazamiento, evidenciando las severas limitaciones de una búsqueda de vecindario simple a la hora de navegar un paisaje topológico altamente rugoso.

2.3 Algoritmo Evolutivo: Algoritmo Genético Básico

La primera metaheurística poblacional implementada es el Algoritmo Genético (AG) Básico. A diferencia de los métodos de trayectoria, este algoritmo procesa simultáneamente un conjunto de soluciones (población de 30 individuos), aplicando operadores de cruce (OX circular), mutación (*2-opt*) y selección (Torneo). El presupuesto se fijó estrictamente en 3000 evaluaciones para garantizar una comparativa justa.

Escenario	Score (Ratio)	Kms	Entropía	Ev. Media	Mejor FObj
Caso 1	1.3591	20.93	15.4031	3000.0	<i>ratio_cuad</i>
Caso 2	1.4277	22.69	15.8888	3000.0	<i>ratio</i>
Caso 3	2.0817	24.39	11.7142	3000.0	<i>exponencia</i>

Tabella 4: Rendimiento del AG Básico empleando la estrategia de multiarranque por función. Los resultados reflejan el mejor individuo hallado explotando la diversidad de las funciones de evaluación.




Figura 2: Evolución de Caja Blanca para el AG Básico. En los Casos 1 y 2 se observa un colapso visual de la curva de exploración (naranja) contra el eje inferior; este fenómeno no es un error algorítmico, sino un artefacto de escala derivado de graficar funciones no lineales (como *ratio_cuad*) en el mismo eje de magnitudes empleado para la entropía y el *Score Universal*.

El análisis de la Tabla 4 y de las trayectorias de convergencia (Figura 2) arroja las siguientes observaciones fundamentales:

- **El Impacto Crítico del Multiarranque por Función:** Al observar los resultados globales, el AG Básico parece exhibir un rendimiento formidable, superando los récords históricos de la Búsqueda Local e incluso igualando la mejor marca conocida en el Caso 2 (1.4277). Sin embargo, este éxito es altamente dependiente del barrido de funciones objetivo. Como se evidencia en la Tabla 4, el algoritmo alcanza sus mejores cotas apoyándose en métricas no lineales (*ratio_cuad* en el Caso 1, *exponencial* en el Caso 3). Cuando se le despoja de esta ventaja y se evalúa puramente sobre la métrica base (Tabla 1.1 de Resultados Parciales), su robustez media se desploma drásticamente.
- **Convergencia y Estancamiento (Caja Blanca):** La dinámica poblacional representada en los gráficos de evolución demuestra una rápida caída del coste

en el primer tercio de la ejecución (≈ 1000 evaluaciones), seguida de una prolongada meseta. A pesar de contar con un operador de mutación para inyectar diversidad, la presión selectiva del modelo generacional y el fuerte sesgo hacia los cruces provocan que la población converja estructuralmente. En el Caso 3, esta convergencia prematura impide al algoritmo navegar la complejidad topológica, resultando en un *Score* de 2.0817, notablemente alejado del óptimo teórico.

- **Inestabilidad Estructural (Caja Negra):** Tal y como se discutirá en el análisis global de robustez, el AG Básico presenta la mayor dispersión de resultados entre los modelos evolutivos (con Coeficientes de Variación cercanos al 6%). Esta volatilidad confirma que la exploración poblacional simple, carente de mecanismos explícitos de especiación o prevención de incesto, es excesivamente sensible a la inicialización estocástica.

2.3.1 Resultados Parciales y Evaluación de Robustez

A diferencia de los Resultados Globales (Tabla 1.2), donde se explota la ventaja del multiarranque mediante un barrido de múltiples funciones de *fitness*, el análisis de Resultados Parciales se restringe estrictamente al uso de la métrica estándar *fobj_ratio* (Kms/Entropía). Esta restricción metodológica es fundamental para evaluar la robustez intrínseca de los algoritmos y su sensibilidad ante la inicialización estocástica (semillas aleatorias), eliminando el sesgo introducido por las métricas no lineales.

A continuación, se presentan los resultados desagregados correspondientes a las 5 ejecuciones independientes para el Algoritmo Genético Básico.

Ejecuciones	Caso 1				Caso 2				Caso 3			
	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr
Ej1	3000	1.5423	24.05	15.5958	3000	1.4277	22.69	15.8888	3000	2.5332	31.41	12.4007
Ej2	3000	1.3772	21.47	15.5934	3000	1.5180	23.60	15.5444	3000	2.3059	27.26	11.8236
Ej3	3000	1.6602	25.59	15.4141	3000	1.5578	24.61	15.7992	3000	2.2254	26.11	11.7307
Ej4	3000	1.5430	23.79	15.4165	3000	1.6102	25.43	15.7936	3000	2.2995	27.50	11.9603
Ej5	3000	1.5429	23.59	15.2903	3000	1.5462	24.20	15.6492	3000	2.1711	26.77	12.3280
Media	3000	1.5331	23.70	15.4620	3000	1.5320	24.10	15.7350	3000	2.3070	27.81	12.0486
Desviación	0	0.0903	1.32	0.1175	0	0.0601	0.93	0.1224	0	0.1236	1.86	0.2689

Tabella 5: Resultados Parciales para el Algoritmo Genético Básico. Las métricas se han calculado exclusivamente bajo la función objetivo estándar (*fobj_ratio*). En negrita se destacan los mejores valores individuales por columna.

2.3.2 Análisis de los Resultados Parciales (AG Básico)

La exposición de las ejecuciones individuales en la Tabla 5 revela la verdadera naturaleza estocástica del Algoritmo Genético Básico cuando no cuenta con el respaldo de múltiples métricas de evaluación:

- **Alta Volatilidad y Dispersión Estructural:** Los valores de desviación estándar de la Función Objetivo (0.0903 en el Caso 1, 0.0601 en el Caso 2 y 0.1236 en el Caso 3) evidencian una variabilidad significativa entre ejecuciones. Esta volatilidad implica que la calidad de la solución final depende en gran medida del muestreo aleatorio inicial y de los primeros cruzamientos, careciendo de mecanismos endógenos fuertes para recuperarse de cuencas de atracción subóptimas.
- **Decadencia del Rendimiento Medio:** Al analizar la media global, el *Score* del AG Básico se desploma a niveles de 1.5331 (Caso 1) y 2.3070 (Caso 3). Estos valores medios se acercan peligrosamente a los obtenidos por métodos mucho más simples como la Búsqueda Local del Primer Mejor, lo que corrobora empíricamente que la exploración poblacional simple no garantiza una explotación óptima continua si no se fuerza la diversidad.
- **Destellos de Calidad Aislados:** A pesar de la pobre robustez media, el algoritmo es capaz de alcanzar soluciones de altísima calidad en semillas puntuales (como la **Ej2** en el Caso 1 con 1.3772, o la **Ej1** en el Caso 2 con 1.4277). Esto confirma que el motor genético (cruce OX y mutación *2-opt*) posee la capacidad operativa necesaria para ensamblar rutas eficientes, pero requiere urgentemente de un paradigma superior (como CHC o Multimodal) para guiar sistemáticamente a toda la población hacia dichas cotas óptimas.

2.4 Algoritmo Evolutivo: CHC (Cross-Generational Elitist Selection, Heterogeneous Recombination and Cataclysmic Mutation)

El segundo modelo poblacional evaluado es el algoritmo CHC. Este enfoque diverge significativamente del Algoritmo Genético Básico al prescindir por completo del operador de mutación. Su capacidad de exploración y mantenimiento de la diversidad se fundamenta en dos pilares: la prevención de incesto diferencial (restringiendo el cruce a padres cuya distancia topológica supere un umbral) y los reinicios poblacionales (cataclismos) cuando la búsqueda se estanca.

Escenario	Score (Ratio)	Kms	Entropía	Ev. Media	Mejor FObj
Caso 1	1.3576	20.93	15.4210	3000.5	<i>ratio</i>
Caso 2	1.4277	22.69	15.8888	3001.3	<i>suma_ponde</i>
Caso 3	2.0116	23.42	11.6435	3001.7	<i>suma_ponde</i>

Tabella 6: Rendimiento del Algoritmo CHC bajo el esquema de multiarranque por función. Se registra un ligero exceso sobre las 3000 evaluaciones debido a la reevaluación de la población durante el último ciclo de reinicio.




Figura 3: Evolución de Caja Blanca para el algoritmo CHC. Las caídas escalonadas en la Función Objetivo representan las fases de convergencia, seguidas de reinicios poblacionales que reinyectan diversidad estructural al sistema.

Del estudio de los datos numéricos (Tabla 6) y la dinámica de convergencia (Figura 3), se derivan las siguientes conclusiones de alto impacto:

- **Supremacía en Calidad y Resolución del Caso 3:** El algoritmo CHC se corona como el método más eficaz de toda la experimentación. En el Caso 1 logra igualar el récord absoluto (1.3576), mientras que en el Caso 2 alcanza el óptimo de la meseta (1.4277). Su verdadera potencia, sin embargo, se manifiesta en el Caso 3: frente a la degradación sufrida por el AG Básico, el CHC logra alcanzar la cota óptima histórica de 2.0116. Esto demuestra que su mecanismo de diversidad estructurada es sumamente resiliente ante redes asimétricas con estaciones vacías.
- **Dinámica de Reinicios y Prevención de Incesto (Caja Blanca):** Las gráficas de evolución muestran el patrón característico en "escalera" del CHC. La población converge rápidamente, lo que provoca la reducción paulatina del umbral de incesto. Cuando este umbral desciende por debajo de cero (estancamiento sostenido), el algoritmo ejecuta un reinicio: preserva la mejor solución

hallada y aleatoriza el resto de los individuos. Los registros internos indican que, sobre las 5 semillas evaluadas con `fobj_ratio`, el sistema ejecuta una media de aproximadamente 3.4 a 3.6 reinicios por ejecución en los tres escenarios (los mejores runs del barrido global llegaron a 4–5). Esta consistencia valida la elección teórica del umbral inicial ($L/4 = 3$), demostrando estar perfectamente calibrado para permitir múltiples ciclos de exploración profunda dentro del presupuesto de 3000 evaluaciones.

- **Eficacia de la Distancia de Hamming por Arcos:** El éxito rotundo de la prevención de incesto corrobora la hipótesis de diseño fundamental de esta práctica. Al evaluar la similitud entre progenitores midiendo la coincidencia de *arcos* en lugar de posiciones absolutas, el CHC logra emparejar cromosomas que son genuinamente diferentes a nivel topológico. Esta gestión precisa de la divergencia compensa con creces la ausencia de un operador de mutación, guiando la búsqueda hacia óptimos globales de forma mucho más fiable que la selección probabilística estándar.

2.4.1 Resultados Parciales y Evaluación de Robustez

A continuación, se presentan los resultados desagregados correspondientes a las 5 ejecuciones independientes para el Algoritmo Genético CHC.

Ejecuciones	Caso 1				Caso 2				Caso 3			
	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr
Ej1	3000	1.4032	21.46	15.2903	3000	1.5009	22.95	15.2929	3000	2.2651	26.54	11.7158
Ej2	3000	1.3576	20.93	15.4210	3000	1.4377	22.69	15.7793	3000	2.1579	26.84	12.4367
Ej3	3000	1.3741	20.93	15.2355	3000	1.4912	22.92	15.3710	3000	2.2097	27.40	12.3983
Ej4	3000	1.3665	20.93	15.3203	3018	1.4640	22.77	15.5512	3000	2.1672	25.96	11.9801
Ej5	3000	1.3686	20.93	15.2963	3000	1.5009	22.95	15.2929	3000	2.0512	21.54	10.5030
Media	3000	1.3740	21.04	15.3127	3004	1.4789	22.86	15.4575	3000	2.1702	25.66	11.8068
Desviación	0	0.0156	0.21	0.0608	7	0.0247	0.11	0.1866	0	0.0705	2.11	0.7050

Tabella 7: Resultados Parciales para el Algoritmo Genético CHC. Las métricas se basan exclusivamente en la función `fobj_ratio`. Se aprecian variaciones marginales en el número de evaluaciones (Ej4 del Caso 2) inherentes a la reevaluación poblacional durante los reinicios cataclísmicos.

2.4.2 Análisis de los Resultados Parciales (CHC)

La evaluación del algoritmo CHC bajo la métrica estricta de ratio puro (Tabla 7) pone de manifiesto la excepcional solidez de su diseño algorítmico, consolidándolo como el método más fiable de toda la experimentación poblacional:

- **Robustez Extrema y Mínima Dispersión:** El dato más revelador es la desviación estándar de la Función Objetivo en las cinco ejecuciones independientes. Con valores de 0.0156 (Caso 1), 0.0247 (Caso 2) y 0.0705 (Caso 3), el algoritmo CHC exhibe la dispersión más baja de todos los modelos analizados. Esta estabilidad extrema certifica que la convergencia del algoritmo es prácticamente insensible a la inicialización estocástica, garantizando resultados de alta calidad de forma sistemática.
- **Dominio Absoluto de la Calidad Media:** A diferencia del AG Básico, que dependía del barrido de funciones objetivo para sostener su competitividad, el CHC domina de manera concluyente en el escenario de evaluación estricta. Sus medias globales de Función Objetivo (1.3740, 1.4789 y 2.1702) superan con amplio margen a las del modelo Básico (1.5331, 1.5320 y 2.3070). Este comportamiento demuestra empíricamente que la combinación de prevención de incesto y reinicios proporciona una capacidad de exploración global muy superior a la mutación tradicional.
- **Replicación de Óptimos Históricos:** Incluso bajo el rigor de una única función de evaluación, el CHC es capaz de aislar soluciones óptimas de forma consistente. En el Caso 1, la **Ej2** alcanza el récord absoluto de 1.3576; en el Caso 2, la misma semilla logra la cota óptima de 1.4377; y en el Caso 3, caracterizado por una alta asimetría, la **Ej5** desciende hasta 2.0512 (muy cerca del récord global de 2.0116). Estos resultados validan de forma irrefutable la eficacia de su estrategia de mantenimiento de diversidad.

2.5 Algoritmo Evolutivo: Multimodal (Clearing)

El tercer enfoque poblacional evaluado es el Algoritmo Genético Multimodal basado en el paradigma de *Clearing*. Este modelo hereda la estructura y operadores del Algoritmo Genético Básico (cruce OX al 90%, mutación *2-opt*, selección por torneo y modelo generacional con elitismo), pero introduce una fase de penalización espacial previa a la selección. Su objetivo principal no es converger hacia una única solución óptima, sino preservar simultáneamente múltiples óptimos locales o globales en nichos estructuralmente disjuntos.

Escenario	Score (Ratio)	Kms	Entropía	Ev. Media	Mejor FObj
Caso 1	1.3576	20.93	15.4210	3000.0	<i>suma_ponde</i>
Caso 2	1.4377	22.69	15.7793	3000.0	<i>ratio</i>
Caso 3	2.0268	23.74	11.7122	3000.0	<i>suma_ponde</i>

Tabella 8: Rendimiento del Algoritmo Genético Multimodal (*Clearing*). La parametrización de nicho se fija en un radio de especiación $\sigma = 3$ ($L/4$) y una capacidad $\kappa = 1$.




Figura 4: Evolución de Caja Blanca para el AG Multimodal (*Clearing*). Se aprecia una convergencia escalonada, donde la preservación de la diversidad estructural previene el colapso prematuro observado en el AG Básico.

La integración de los datos de la Tabla 8, la evolución visual (Figura 4) y el contexto teórico del método permiten establecer las siguientes deducciones analíticas:

- **Compromiso entre Calidad Absoluta y Diversidad:** El algoritmo Multimodal demuestra una capacidad excepcional para evitar óptimos locales mediocres, superando holgadamente al AG Básico puro. En el Caso 1, logra empatar el récord absoluto (1.3576). En el Caso 3, mejora drásticamente el rendimiento frente al enfoque poblacional básico (2.0268 frente a 2.0817). No obstante, al comparar su calidad extrema con la del algoritmo CHC (que logra 2.0116 en el Caso 3), se evidencia el *trade-off* inherente al *Clearing*: al forzar a la población a distribuirse en múltiples nichos disjuntos, se diluye parcialmente la presión selectiva hacia el óptimo global absoluto.
- **Eficacia del Radio Basado en Arcos:** La configuración del nicho espacial ($\sigma = 3$, $\kappa = 1$) depende críticamente de la métrica de distancia de Hamming adaptada a arcos. Al penalizar soluciones que comparten demasiadas transiciones topológicas, el algoritmo garantiza que los individuos dominantes

representen esquemas de rutas genuinamente distintos. La capacidad unitaria ($\kappa = 1$) asegura una Caja Blanca limpia, donde cada pico en el espacio de búsqueda es representado por un único "campeón", maximizando el número de nichos explorados simultáneamente con una población restringida de 30 individuos.

- **Sobrecarga Computacional (Overhead):** Aunque el número de evaluaciones de la función objetivo se mantiene rígidamente en 3000, los registros internos de ejecución revelan un incremento en el tiempo de CPU (promediando ≈ 0.147 s frente a los ≈ 0.055 s del AG Básico y CHC). Este aumento de casi el triple en el tiempo físico de ejecución es consecuencia directa de la complejidad algorítmica del *Clearing*, que exige calcular una matriz completa de distancias de Hamming entre todos los individuos de la población en cada generación para determinar la dominancia espacial y aplicar las penalizaciones.

2.5.1 Resultados Parciales y Evaluación de Robustez

A continuación, se presentan los resultados desagregados correspondientes a las 5 ejecuciones independientes para el Algoritmo Genético Multimodal basado en el paradigma de *Clearing*.

Ejecuciones	Caso 1				Caso 2				Caso 3			
	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr	#Ev	F OBJ	Kms	Entr
Ej1	3000	1.4918	22.88	15.3395	3000	1.5299	23.95	15.6582	3000	2.2055	25.84	11.7142
Ej2	3000	1.3692	20.93	15.2903	3000	1.4640	22.77	15.5512	3000	2.2150	27.64	12.4794
Ej3	3000	1.3585	20.93	15.4100	3000	1.4377	22.69	15.7793	3000	2.1689	25.36	11.6932
Ej4	3000	1.3585	20.93	15.4100	3000	1.5732	24.80	15.7635	3000	2.2289	27.13	12.1728
Ej5	3000	1.3692	20.93	15.2903	3000	1.4377	22.69	15.7793	3000	2.0571	24.10	11.7142
Media	3000	1.3894	21.32	15.3480	3000	1.4885	23.38	15.7063	3000	2.1751	26.01	11.9547
Desviación	0	0.0514	0.78	0.0537	0	0.0541	0.86	0.0898	0	0.0622	1.27	0.3184

Tabella 9: Resultados Parciales para el Algoritmo Genético Multimodal (*Clearing*). Las métricas se han calculado puramente bajo la función `fobj_ratio`, garantizando una comparativa directa con los modelos anteriores.

2.5.2 Análisis de los Resultados Parciales (AG Multimodal)

El análisis de la métrica de evaluación pura (Tabla 9) posiciona al Algoritmo Genético Multimodal en un claro punto intermedio entre la volatilidad del AG Básico y la robustez extrema del CHC:

- **Mejora Sustancial frente al Básico:** La introducción de la fase de penalización espacial (*Clearing*) logra mitigar considerablemente la convergencia

prematura observada en el AG Básico. Las desviaciones estándar de la Función Objetivo (0.0514, 0.0541 y 0.0622) demuestran una volatilidad mucho más contenida. En paralelo, las medias globales (1.3894, 1.4885 y 2.1751) reflejan un incremento sustancial en la fiabilidad del algoritmo para encontrar cuencas de atracción de alta calidad de forma sistemática.

- **El Coste del Mantenimiento de Nichos:** Aunque el *Clearing* es superior al enfoque básico, no alcanza la estabilidad casi absoluta del CHC. Este comportamiento es teóricamente coherente: al forzar a la población a distribuirse y sostener simultáneamente múltiples nichos espaciales (limitando la capacidad de los mismos a $\kappa = 1$), el algoritmo diluye parte de la presión selectiva que de otro modo se orientaría a explotar en profundidad el mejor óptimo global conocido.
- **Aislamiento de Cuestas Óptimas:** Pese a dispersar su esfuerzo exploratorio, el AG Multimodal logra identificar soluciones de élite en ejecuciones específicas, demostrando la validez empírica de sus subpoblaciones. Logra extraer *Scores* excepcionales como 1.3585 en el Caso 1 (**Ej3** y **Ej4**), 1.4377 en el Caso 2 (**Ej3** y **Ej5**), y un muy competitivo 2.0571 en el exigente Caso 3 (**Ej5**).

2.6 Caso 1 - Análisis de Caja Negra: Robustez y Error Relativo

El análisis de Caja Negra prescinde del comportamiento interno de los algoritmos para centrarse puramente en la calidad final y la estabilidad de las soluciones obtenidas frente a la variabilidad estocástica. Para garantizar la equidad, este análisis utiliza exclusivamente la función objetivo estándar (`fobj_ratio`) a lo largo de las 5 ejecuciones de prueba.

Se evalúan dos métricas fundamentales: el Coeficiente de Variación (CV), que cuantifica la dispersión relativa y por ende la robustez del modelo, y el Error Relativo Porcentual (RPD) de la mejor de las cinco ejecuciones, calculado respecto a la mejor solución histórica conocida de las prácticas anteriores (fijada en 1.3665 para el Caso 1)

Algoritmo	Media	Std (σ)	CV (%)	RPD (%)
Básico	1.53	0.09	5.89	0.78
CHC	1.37	0.02	1.13	-0.65
Multimodal	1.39	0.05	3.70	-0.58

Tabella 10: Métricas de Caja Negra (Caso 1). El RPD negativo indica una superación del óptimo histórico conocido. El RPD se mide sobre la mejor de las cinco ejecuciones; la Media, σ y CV describen la distribución completa.




Figura 5: Diagrama de Caja y Bigotes (Caso 1). Ilustra la dispersión de la Función Objetivo en las 5 ejecuciones independientes.

Del cruce de los datos estadísticos y la representación visual de la Figura 5, se extraen las siguientes observaciones clave:

- **Robustez y Estabilidad (CV):** El algoritmo CHC demuestra una estabilidad excepcional, registrando el menor Coeficiente de Variación (1.13%). El diagrama de caja corrobora visualmente esta consistencia: la caja representativa de CHC es extremadamente compacta. Por el contrario, el AG Básico presenta un CV del 5.89%; su diagrama revela una caja ancha con valores atípicos (*outliers*) severos en ambos extremos, lo que penaliza gravemente su fiabilidad. El Multimodal se sitúa en un espectro intermedio de robustez (3.70%), mejorando la estabilidad del Básico gracias a su penalización espacial.

- **Quiebre del Estado del Arte (RPD Negativo):** El hito más destacado de este análisis es la obtención de un RPD negativo. Tanto el algoritmo CHC (-0.65% , alcanzando un F.Obj de 1.3576) como el Multimodal (-0.58% , con 1.3585) logran batir la mejor marca histórica de las prácticas basadas en trayectorias (1.3665). Esto certifica el valor añadido de las técnicas poblacionales, capaces de hallar nuevas mesetas de optimización inaccesibles para algoritmos constructivos o de vecindario simple.

2.7 Caso 1 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos

El análisis de Caja Blanca permite examinar la dinámica interna de los algoritmos evolutivos durante su ejecución, superando la visión limitante del coste final para comprender *cómo* navegan el espacio de búsqueda. Este bloque aborda la diversificación estructural, el mecanismo diferencial del CHC y la distribución espacial del Multimodal.

2.7.1 Diversificación Estructural: Posición vs. Arcos

Como se argumentó en las decisiones de diseño, medir la similitud entre secuencias basándose en posiciones absolutas (*overlap*) resulta engañoso para este problema. La verdadera métrica de diversidad reside en los arcos (tramos consecutivos).

- **Métrica de Posición (Hamming Clásica):** Los tres algoritmos muestran tasas de solapamiento (*overlap*) en los primeros 4 genes extremadamente bajas (10.0% para Básico y CHC, 22.5% para Multimodal). Si se tomara esta métrica como referencia, se concluiría erróneamente que las poblaciones son casi disjuntas en su totalidad.
- **Métrica de Arcos (Hamming Adaptada):** Conviene precisar que esta métrica compara las mejores soluciones de las cinco ejecuciones independientes (reproducibilidad del campeón entre semillas), no la dispersión interna de una población; la multimodalidad intra-poblacional se documenta aparte mediante el número de dominantes. Al medir la proporción de arcos distintos entre las soluciones, se obtiene una imagen mucho más realista. El AG Básico presenta un 67.7% de arcos distintos, mientras que el **CHC eleva esta diversidad al 73.1%**. Sorprendentemente, el Multimodal registra la menor diversidad de arcos (54.6%). Este fenómeno se explica por la fiabilidad del Clearing: al converger su campeón hacia las mismas configuraciones de arcos de alta

calidad de forma consistente entre semillas, las soluciones finales de ejecuciones distintas se parecen más entre sí (menor diversidad inter-ejecución), pese a que dentro de cada población se sostengan múltiples nichos.

2.7.2 Convergencia y Reinicios del Algoritmo CHC

El comportamiento del algoritmo CHC se caracteriza por fases de explotación agresiva interrumpidas por eventos cataclísmicos, tal y como se ilustra en las Figuras 6, 7 y 8.




Figura 6: Convergencia global del CHC (Caso 1) para las 5 semillas. Las caídas escalonadas muestran la fase de explotación, mientras que las líneas verticales rojas marcan los momentos exactos en los que el umbral de incesto cae por debajo de cero y se desencadenan los reinicios




Figura 7: Convergencia detallada (Mejor/Media/Peor) para una ejecución representativa.




Figura 8: Diversidad genética del CHC (Hamming normalizada).

- **Dinámica de Convergencia:** El análisis paramétrico reporta una media de 3.4 reinicios por ejecución (rango de 3 a 4). La Figura 6 demuestra la notable

consistencia de este patrón a través de las diferentes semillas. Analizando en detalle una ejecución específica (Figura 7), se observa cómo en cada ciclo, el peor individuo y la media convergen aceleradamente hacia la mejor solución. Cuando el sistema reinicia (marcado por las líneas verticales), el coste del peor individuo y la media poblacional se disparan instantáneamente debido a la aleatorización, preservando intacta la mejor marca.

- **Diversidad Genética Evolutiva:** La Figura 8 corrobora visualmente este mecanismo mecánico. La diversidad arranca en niveles altísimos (≈ 0.9) debido a la inicialización aleatoria, y colapsa hacia cero conforme el algoritmo agota las parejas recombinables. Cada reinicio actúa como un "rebote", elevando de nuevo la métrica (promediando 0.607 en las últimas 10 generaciones de la ejecución). Esta es la representación empírica perfecta de la teoría del CHC: divergencia vía reinicio y convergencia vía prevención de incesto.

2.7.3 Dinámica de Nichos en el Algoritmo Multimodal (*Clearing*)

Para evaluar la efectividad de la fase de *Clearing*, se ha monitorizado el número de individuos "dominantes" (campeones de nicho que sobreviven a la penalización) en cada generación, como se ilustra en la Figura 9.




Figura 9: Dinámica del *Clearing*: Número de dominantes (nichos) por generación. La banda representa la variabilidad entre las 5 semillas.

El gráfico demuestra de forma inequívoca el éxito del paradigma:

- **Estabilidad Multimodal:** Tras el transitorio inicial, el número de dominantes no colapsa hacia 1 (lo que implicaría convergencia prematura), sino que se

estabiliza en una media global de 23.9 nichos sobre una población total de 30 individuos.

- **Exploración Sostenida:** El hecho de mantener la población repartida de forma constante (rango entre 15 y 30 dominantes) durante las 100 generaciones virtuales de la ejecución certifica que el algoritmo explora topologías disjuntas de forma paralela. Esta distribución estructural explica la alta robustez paramétrica evidenciada previamente en la Caja Negra.

2.8 Caso 2 - Análisis de Caja Negra: Robustez y Error Relativo

Continuando con la evaluación de robustez, se presenta el análisis de Caja Negra para el Caso 2. La métrica de referencia histórica a batir en este escenario se sitúa en 1.4377.

Algoritmo	Media	Std (σ)	CV (%)	RPD (%)
Básico	1.53	0.06	3.92	-0.69
CHC	1.48	0.02	1.67	-0.00
Multimodal	1.49	0.05	3.64	-0.00

Tabella 11: Métricas de Caja Negra (Caso 2). Destaca el RPD negativo del AG Básico, indicando el hallazgo de un nuevo óptimo global para este escenario. El RPD se mide sobre la mejor de las cinco ejecuciones; la Media, *1sigma* y CV describen la distribución completa.




Figura 10: Diagrama de Caja y Bigotes (Caso 2). Se evidencia la disparidad en la dispersión entre el CHC y los otros dos modelos evolutivos.

El análisis integrado de las métricas (Tabla 11) y la distribución visual (Figura 10) revela las siguientes dinámicas operativas:

- **Consolidación de la Estabilidad del CHC:** El algoritmo CHC revalida su posición como el modelo más predecible y estable, exhibiendo un CV de apenas 1.67%. Su diagrama de caja es notablemente compacto y se sitúa en un rango inferior, lo que garantiza un rendimiento medio superior (1.48) constante entre ejecuciones. El Multimodal, aunque presenta una caja más elongada (CV del 3.64%), logra mantener una mediana muy competitiva, confirmando la utilidad del paradigma *Clearing*.
- **El Fenómeno Estocástico del AG Básico:** El dato más llamativo de este escenario es el RPD negativo alcanzado por el AG Básico (-0.69% , correspondiente a un F.Obj de 1.4277), que quiebra el estado del arte conocido. Sin embargo, al observar el diagrama de caja, queda patente que este valor es un *outlier* aislado (representado por el círculo en la parte inferior de la Figura 10). La caja principal del Básico se encuentra significativamente por encima de la de sus competidores, con la peor media (1.53). Esto demuestra que, si bien el motor genético tiene el potencial teórico para alcanzar mesetas óptimas

inéditas, carece de la robustez sistémica para hacerlo de forma determinista, dependiendo fuertemente de la "suerte" estocástica en la semilla inicial.

- **Convergencia en el Óptimo Histórico:** Cabe destacar que tanto el algoritmo CHC como el Multimodal logran igualar con precisión milimétrica la mejor marca histórica conocida (RPD del -0.00% , alcanzando 1.4377), lo que subraya la eficacia de sus mecanismos de diversidad para no quedar atrapados en óptimos locales prematuros.

2.9 Caso 2 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos

Para complementar los hallazgos de robustez del Caso 2, se examina el comportamiento interno de los modelos mediante métricas de Caja Blanca, prestando especial atención a cómo la topología de la red afecta la diversidad y la convergencia respecto al escenario anterior.

2.9.1 Diversificación Estructural: Posición vs. Arcos

Se revalida la importancia de medir la similitud estructural mediante arcos en lugar de posiciones absolutas en la secuencia:

- **Métrica de Posición (Hamming Clásica):** La tasa de solapamiento (*overlap*) en los primeros 4 genes aumenta ligeramente respecto al Caso 1, situándose en 25.0% para el Básico, 17.5% para el CHC y 27.5% para el Multimodal. Si bien sugieren una diversidad aceptable, estas cifras enmascaran la verdadera similitud de las rutas.
- **Métrica de Arcos (Hamming Adaptada):** Al evaluar la proporción de transiciones topológicas distintas, el escenario cambia. El AG Básico mantiene una alta diversidad de arcos (67.7%), seguido por el CHC (62.3%). Nuevamente, el Algoritmo Multimodal presenta la menor diversidad estructural (59.2%). Este patrón confirma de manera consistente que el Clearing converge su campeón hacia las mismas subestructuras de alta calidad entre semillas: las soluciones finales de ejecuciones distintas se parecen más entre sí (menor diversidad inter-ejecución), aunque dentro de cada población se sostengan simultáneamente múltiples nichos.

2.9.2 Convergencia y Reinicios del Algoritmo CHC (Caso 2)

La estabilidad de la estrategia de diversidad del CHC se pone a prueba en este segundo escenario, documentando sus ciclos de exploración y explotación a través de las Figuras 11, 12 y 13.




Figura 11: Convergencia global del CHC (Caso 2). Las cinco ejecuciones independientes muestran un comportamiento escalonado altamente predecible, con las líneas verticales indicando los reinicios cataclísmicos dictados por el agotamiento del umbral de incesto.




Figura 12: Convergencia detallada (Mejor/Media/Peor) de la semilla 382941 en el Caso 2.




Figura 13: Diversidad genética del CHC basada en la métrica de arcos normalizada (Caso 2).

- **Frecuencia de Reinicios:** Las ejecuciones registran una media de 3.6 reinicios (rango de 3 a 4), un valor prácticamente idéntico al del Caso 1. Esta consistencia transversal confirma que el umbral de incesto inicial seleccionado dota al algoritmo de un ritmo de exploración independiente de la topología particular de la instancia.

- **Gestión de la Diversidad:** La Figura 13 ilustra cómo la diversidad media en las últimas 10 generaciones de la ejecución se sitúa en 0.461. La caída progresiva de la diversidad precede invariablemente a un estancamiento en la curva de convergencia (Figura 12), momento en el cual el reinicio interviene reinyectando entropía genética sin recurrir a la mutación clásica, garantizando así la fuga de mínimos locales.

2.9.3 Dinámica de Nichos en el Algoritmo Multimodal (Caso 2)

Para validar que el *Clearing* no pierde efectividad al cambiar de escenario, se analiza el número de dominantes generacionales.




Figura 14: Dinámica del *Clearing* en el Caso 2. El número de dominantes (nichos activos) se mantiene constante a lo largo de todo el proceso evolutivo.

- **Sostenibilidad Estructural:** La Figura 14 muestra que el algoritmo sostiene una media global de **23.4** dominantes (sobre una población de 30), oscilando en un rango estable de 15 a 30 nichos a lo largo de las 100 generaciones.
- **Conclusión de la Dinámica:** Este comportamiento es la prueba de Caja Blanca de que el Multimodal es genuinamente efectivo: no satura la población en una única configuración dominante, sino que fuerza a los individuos a distribuirse por diferentes regiones del espacio de búsqueda, explicando su robustez observada en el análisis de Caja Negra.

2.10 Caso 3 - Análisis de Caja Negra: Robustez y Error Relativo

Finalmente, se aborda el análisis de Caja Negra para el Caso 3, el escenario más exigente de la experimentación debido a su topología altamente asimétrica y la presencia de numerosas estaciones de bicicletas vacías. La mejor marca histórica de referencia para este problema se sitúa en 2.0116.

Algoritmo	Media	Std (σ)	CV (%)	RPD (%)
Básico	2.31	0.12	5.36	7.93
CHC	2.17	0.07	3.25	1.97
Multimodal	2.18	0.06	2.86	2.26

Tabella 12: Métricas de Caja Negra (Caso 3). Ningún algoritmo logra un RPD negativo bajo la evaluación estricta de la métrica `fobj_ratio`, evidenciando la extrema complejidad del escenario. El RPD se mide sobre la mejor de las cinco ejecuciones; la Media, *1sigma* y CV describen la distribución completa.




Figura 15: Diagrama de Caja y Bigotes (Caso 3). Se observa la clara superioridad del CHC y el Multimodal frente a la alta volatilidad y pobre rendimiento medio del AG Básico.

La interpretación transversal de los resultados (Tabla 12) y la distribución visual (Figura 15) arrojan las siguientes conclusiones decisivas:

- **El Filtro de la Asimetría Topológica:** El Caso 3 actúa como un discriminador algorítmico implacable. El AG Básico sufre una severa degradación de calidad: aunque su mejor ejecución queda a un 7.93% del óptimo conocido (RPD), su media se aleja casi un 15%, mostrando además el mayor grado de inestabilidad (CV de 5.36%). Su diagrama de caja se ubica en un rango de costes inaceptablemente alto, confirmando que la mutación simple combinada con una selección por torneo —carente de mecanismos explícitos de especiación o prevención de incesto— es netamente insuficiente para estructurar rutas eficientes en entornos asimétricos severos.
- **Robustez Compartida (CHC y Multimodal):** En contraste, los modelos genéticos avanzados logran contener el impacto de la complejidad espacial. El Algoritmo Multimodal registra la menor dispersión estadística (CV del 2.86%, $\sigma = 0.06$), mostrándose marginalmente más estable que el CHC (CV del 3.25%). Visualmente, las cajas principales de ambos algoritmos se solapan en el mismo estrato de alta calidad. Además, ambos modelos presentan valores atípicos inferiores (los círculos por debajo de sus cajas), lo que indica que en ejecuciones afortunadas logran exprimir aún más la Función Objetivo, aislando soluciones de élite.
- **Distancia al Óptimo (RPD Positivo):** A diferencia de los Casos 1 y 2, ningún modelo logra quebrar la marca histórica utilizando puramente el `fobj_ratio` puro. El CHC es el que más se aproxima al límite absoluto, con un RPD de +1.97%. Sin embargo, es vital recordar que bajo el paradigma del multiarranque de funciones (documentado en la Tabla 1.2), el algoritmo CHC sí logró converger exactamente en el récord de 2.0116. La incapacidad de lograrlo de forma sistemática y media bajo una única métrica subraya la gran dificultad de escapar de los mínimos locales profundos que caracterizan este último escenario.

2.11 Caso 3 - Análisis de Caja Blanca: Diversificación, Convergencia y Nichos

Para concluir la disección del tercer escenario, se evalúa el comportamiento interno de los modelos mediante las métricas de Caja Blanca. Este análisis es crítico para entender cómo la topología asimétrica del Caso 3 impacta en la exploración y la diversidad genética de las poblaciones.

2.11.1 Diversificación Estructural: Posición vs. Arcos

El paisaje de búsqueda fragmentado del Caso 3 fuerza a los algoritmos a recorrer un mayor espectro de soluciones topológicas, lo cual se refleja claramente en las métricas de diversidad:

- **Métrica de Posición (Hamming Clásica):** La tasa de solapamiento en los primeros 4 genes refleja valores de ****17.5%**** para el Básico, ****12.5%**** para el CHC y un notable ****32.5%**** para el Multimodal. Si bien el Multimodal parece tener un alto solapamiento, la métrica por arcos desmiente cualquier supuesta convergencia total.
- **Métrica de Arcos (Hamming Adaptada):** Al cuantificar los tramos físicos reales, se observa la mayor tasa de diversidad estructural de todos los escenarios evaluados. El AG Básico explora un ****75.0%**** de arcos distintos, el CHC un ****72.9%**** y el Multimodal un ****70.0%****. Este incremento generalizado en la diversidad de arcos (comparado con el $\approx 60 - 65\%$ de los Casos 1 y 2) evidencia que la asimetría del problema dificulta la convergencia hacia una única ruta ideal, obligando a los algoritmos a mantener una alta variedad de sub-rutas activas. Fiel a su paradigma, el Multimodal sigue registrando la menor diversidad inter-ejecución de los tres: su campeón converge de forma reproducible entre semillas, aun cuando cada población mantenga activos múltiples nichos.

2.11.2 Convergencia y Reinicios del Algoritmo CHC (Caso 3)

La robustez de la estrategia de diversidad sin mutación del CHC se somete a su prueba más severa, documentada en las Figuras 16, 17 y 18.




Figura 16: Convergencia global del CHC (Caso 3). Las cinco ejecuciones mantienen el patrón de búsqueda por escalones, demostrando que el mecanismo de reinicio se acciona de forma fiable ante el estancamiento, independientemente de la dificultad del escenario.




Figura 17: Convergencia detallada (Mejor/Media/Peor) de la semilla 382941 en el Caso 3.




Figura 18: Diversidad genética del CHC basada en la métrica de arcos normalizada (Caso 3).

- **Resiliencia del Ciclo de Exploración:** Las ejecuciones registran una media de **3.4** reinicios (rango de 3 a 4). Resulta extraordinario constatar que, a pesar de la extrema dificultad del Caso 3, la frecuencia de los cataclismos poblacionales es idéntica a la de los Casos 1 y 2. Esto demuestra que la calibración del umbral de incesto ($L/4$) regula el ritmo de convergencia de manera matemáticamente estable frente a cualquier topología.
- **Gestión de la Diversidad:** La Figura 18 refleja que la diversidad media en las últimas 10 generaciones de la ejecución se eleva ligeramente a **0.568** (frente al 0.461 del Caso 2). Los picos de máxima diversidad coinciden puntualmente con los reinicios poblacionales, demostrando que la reinyección de alea-

toriedad (copiando únicamente al mejor) es un motor de divergencia suficiente y superior a la mutación clásica empleada por el AG Básico.

2.11.3 Dinámica de Nichos en el Algoritmo Multimodal (Caso 3)

Finalmente, se evalúa si la asimetría espacial provoca el colapso del paradigma *Clearing*.




Figura 19: Dinámica del *Clearing* en el Caso 3. La banda de variabilidad ilustra cómo la población mantiene activos múltiples frentes de búsqueda durante las 100 generaciones.

- **Sostenibilidad Estructural ante la Asimetría:** El gráfico de la Figura 19 despeja cualquier duda sobre la robustez del método. El algoritmo no sólo no colapsa, sino que sostiene una media global de **24.3** dominantes (el valor más alto de los tres casos), fluctuando en una banda segura de 14 a 30 nichos.
- **Multimodalidad Efectiva:** Mantener casi 25 campeones distintos en un escenario tan restrictivo confirma que el algoritmo dedica un enorme esfuerzo a evaluar aproximaciones topológicas alternativas, garantizando una exploración paralela y blindando la búsqueda contra la convergencia prematura.

2.12 Estudio Paramétrico: Justificación de Decisiones de Diseño

Para dotar de rigor científico a las configuraciones algorítmicas empleadas en la experimentación, se ha llevado a cabo un barrido paramétrico exhaustivo. Este estudio busca justificar empíricamente las elecciones de diseño, demostrando que

los parámetros por defecto no son arbitrarios, sino que representan un punto de equilibrio óptimo (*sweet spot*) entre exploración y explotación.

La metodología del estudio evalúa cada parámetro sobre el **Caso 1** utilizando las 5 semillas independientes y la métrica de rendimiento estricta (`fobj_ratio`). Adicionalmente a las métricas de Caja Negra (Media, Mejor F.Obj, Desviación Estándar y Coeficiente de Variación), se incorpora una métrica de Caja Blanca fundamental para comprender el impacto estructural de los cambios.

2.12.1 Algoritmo Genético Multimodal (Clearing): Radio y Capacidad de Nicho

El rendimiento del paradigma de *Clearing* depende directamente de la definición espacial de sus nichos. Se han sometido a examen sus dos variables de control fundamentales: el radio de exclusión (σ , medido en distancia de arcos) y la capacidad de preservación del nicho (κ). Considerando que la longitud del cromosoma para el Caso 1 es $L = 12$, se han probado los radios correspondientes a $L/12$ (1), $L/4$ (3) y $L/2$ (6).

Radio (σ)	Media F. OBJ	Mejor F. OBJ	Std (σ)	CV (%)	Dominantes Medios
1	1.3860	1.3585	0.0197	1.42	25.7
3 (Defecto)	1.3894	1.3585	0.0514	3.70	23.9
6	1.3833	1.3585	0.0246	1.78	18.8

Tabella 13: Estudio paramétrico del radio de *Clearing* (σ). La métrica de Caja Blanca "Dominantes Medios" indica el número de nichos sostenidos por el algoritmo.

Capacidad (κ)	Media F. OBJ	Mejor F. OBJ	Std (σ)	CV (%)	Dominantes Medios
1 (Defecto)	1.3894	1.3585	0.0514	3.70	23.9
2	1.3909	1.3585	0.0163	1.17	24.1
3	1.4411	1.3741	0.0499	3.46	22.9

Tabella 14: Estudio paramétrico de la capacidad de nicho (κ). Evalúa el impacto de permitir la supervivencia de múltiples individuos dentro del mismo radio de exclusión.

El análisis de las Tablas 13 y 14 proporciona las siguientes justificaciones de diseño empíricas:

- **Alta Robustez frente al Radio Espacial (σ):** El algoritmo demuestra ser notablemente insensible a variaciones drásticas en el radio de *Clearing*. Las tres

configuraciones logran alcanzar el mismo óptimo absoluto individual (1.3585) y presentan medias globales prácticamente idénticas (oscilando entre 1.3833 y 1.3894). Como era esperable desde una perspectiva teórica de Caja Blanca, al incrementar el radio restrictivo ($\sigma = 6$), el número de dominantes decae a 18.8, ya que el área de penalización es mayor y "limpia" a más individuos. La elección de $\sigma = 3$ ($L/4$) se consolida como un valor de compromiso excelente, manteniendo un alto número de nichos (23.9) sin comprometer la convergencia.

- **Impacto de la Capacidad de Nicho (κ):** Permitir la supervivencia de 1 o 2 individuos por nicho produce resultados equivalentes en términos de calidad máxima (1.3585), si bien $\kappa = 2$ aporta una ligera ventaja en estabilidad (CV del 1.17%). Sin embargo, la degradación es patente al incrementar la capacidad a $\kappa = 3$, donde la media asciende a 1.4411 y el algoritmo pierde la capacidad de aislar la solución óptima absoluta. En consecuencia, se justifica plenamente el uso de $\kappa = 1$: garantiza una presión selectiva adecuada, evita la redundancia genética dentro de una misma cuenca de atracción y proporciona una lectura de Caja Blanca mucho más nítida, donde cada individuo sobreviviente representa invariablemente un pico topológico disjunto.

2.12.2 Algoritmo Genético CHC: Umbral Inicial de Incesto

El umbral de incesto determina la agresividad con la que el algoritmo CHC rechaza parejas genéticamente similares, actuando como un regulador crítico entre la explotación de esquemas prometedores y la necesidad de mantener la diversidad. Dado que la longitud del cromosoma es $L = 12$, se han evaluado umbrales correspondientes a $L/12$ (1), $L/4$ (3, valor por defecto) y $L/2$ (6).

Umbral (L/x)	Media F. OBJ	Mejor F. OBJ	Std (σ)	CV (%)	Reinicios
1	1.4327	1.3576	0.0613	4.28	3.8
3 (Defecto)	1.3740	1.3576	0.0156	1.13	3.4
6	1.4863	1.3772	0.0850	5.72	2.6

Tabella 15: Estudio paramétrico del umbral inicial de incesto (L/x). La métrica "Reinicios" indica el número promedio de eventos cataclísmicos disparados por ejecución.

La experimentación permite extraer las siguientes conclusiones sobre la calibración del parámetro:

- **El Punto de Equilibrio (*Sweet Spot*):** El umbral $L/4 = 3$ se confirma como la configuración óptima. Presenta la mejor media (1.3740) y, fundamentalmente, la mayor estabilidad estadística (CV de 1.13%), lo que demuestra que un umbral moderado permite al algoritmo "madurar" las soluciones antes de forzar un cambio drástico.
- **Sensibilidad a la Rigidez del Filtro:**
 - Un umbral bajo ($L/12 = 1$) resulta excesivamente laxo; el algoritmo permite el emparejamiento de individuos muy similares demasiado pronto, lo que acelera la convergencia pero degrada la robustez (CV del 4.28%) al forzar más reinicios (3.8 de media) por estancamiento prematuro.
 - Por el contrario, un umbral elevado ($L/2 = 6$) actúa como un filtro demasiado restrictivo. Al rechazar la mayoría de las parejas, la tasa de recombinación disminuye drásticamente, obligando al algoritmo a realizar menos reinicios (2.6) pero obteniendo soluciones finales significativamente peores (media de 1.4863) al no explorar suficientes combinaciones topológicas.

2.12.3 Algoritmo Genético Básico: Análisis Paramétrico

Para determinar la configuración robusta del AG Básico, se ha realizado un estudio paramétrico sobre el Caso 1, evaluando la sensibilidad del modelo ante variaciones en la probabilidad de cruce, la presión de selección (K), el modelo poblacional y la activación del elitismo.

Parámetro	Valor	Media F. OBJ	Mejor F. OBJ	Std (σ)	CV (%)
Prob. Cruce	0.7	1.5925	1.5113	0.0580	3.64
	0.9	1.5331	1.3772	0.0903	5.89
	1.0	1.5764	1.4087	0.1121	7.11
K Torneo	2	1.4532	1.3927	0.0414	2.85
	3	1.5331	1.3772	0.0903	5.89
	6	1.6690	1.5966	0.0841	5.04
Modelo	Generacional	1.5331	1.3772	0.0903	5.89
	Estacionario	1.6993	1.5810	0.1573	9.25
Elitismo	True	1.5331	1.3772	0.0903	5.89
	False	1.5704	1.3731	0.1773	11.29

Tabella 16: Estudio paramétrico del AG Básico. Se resalta en negrita el valor más competitivo para cada métrica.

- **Probabilidad de Cruce:** El valor 0.9 se consolida como el *sweet spot*. Mientras que una tasa de 0.7 limita la exploración combinatoria, una tasa de 1.0 elimina la mutación correctiva, resultando en una mayor inestabilidad (CV del 7.11%). El 0.9 permite un balance eficaz entre la recombinación de esquemas y la mutación de rescate.
- **Presión de Selección (K):** Se observa un compromiso claro. Un torneo $K = 2$ ofrece la mayor robustez (CV del 2.85%) y mejor media, favoreciendo la diversidad genética. No obstante, el valor por defecto $K = 3$ (seleccionado para garantizar una presión ligeramente superior en entornos de alta entropía) es el que logra alcanzar el mejor óptimo individual (1.3772). Valores altos ($K = 6$) resultan contraproducentes al acelerar excesivamente la convergencia hacia mínimos locales subóptimos.
- **Modelo Poblacional y Elitismo:** La superioridad del modelo *Generacional* sobre el *Estacionario* es manifiesta (1.53 vs 1.69 de media). Asimismo, el uso de elitismo ($E = 1$) es indispensable para la estabilidad: sin él, el CV se dispara hasta el 11.29%. Aunque sin elitismo se puede alcanzar un mejor individuo marginalmente superior por azar (1.3731), la consistencia proporcionada por la preservación del mejor individuo justifica plenamente su inclusión en el diseño definitivo.

2.13 Análisis Visual de Nichos (Caso 1)

La efectividad del algoritmo Multimodal no reside únicamente en su capacidad estadística para reducir la Función Objetivo, sino en su habilidad para preservar simultáneamente soluciones topológicamente disjuntas en el espacio de búsqueda. A continuación, se ilustran tres nichos distintos identificados mediante el operador de *Clearing* en una ejecución representativa (semilla 382941). La distinción entre estos nichos está garantizada por una distancia de Hamming (orientada a arcos) superior al radio σ definido.

Nicho	F. OBJ (Ratio)	Kms	Entropía
Nicho 1	1.4918	22.88	15.3395
Nicho 2	1.5486	23.61	15.2464
Nicho 3	1.7536	27.25	15.5419

Tabella 17: Características topológicas de tres nichos distintos extraídos de la población final.



Figura 20: Nicho 1 (Óptimo local).



Figura 21: Nicho 2 (Alternativa).



Figura 22: Nicho 3 (Exploración).

El análisis de estos nichos permite confirmar la efectividad del paradigma:

- **Exploración Sostenida:** El *Nicho 1* es el mejor representante de esta ejecución concreta (semilla 382941), con un buen compromiso entre kilómetros y entropía; su F.Obj de 1.4918 ilustra el campeón de un nicho, no el óptimo global de la práctica (1.3585, alcanzado por otras semillas). Por su parte, el *Nicho 3* propone un recorrido con una mayor distancia (27.25 Kms) pero una entropía superior (15.5419), demostrando que el algoritmo no ha convergido forzosamente a una única topología, sino que mantiene rutas alternativas válidas que podrían ser preferibles bajo diferentes criterios operativos de la red.
- **Validación de la Multimodalidad:** La variabilidad en los recorridos visualizados en los mapas corrobora que el mecanismo de *Clearing* no solo etiqueta

a individuos como "dominantes" por conveniencia algorítmica, sino que realmente preserva diversidad estructural real. Esta capacidad de "multitasking" evolutivo es la que dota al modelo de su alta robustez frente a cambios en la topología de la red.

3 Observaciones y Conclusiones

Tras el análisis exhaustivo del comportamiento de los algoritmos evolutivos frente a las técnicas de trayectoria, se presentan las conclusiones finales estructuradas según los objetivos de rendimiento, robustez y diseño algorítmico.

3.1 Síntesis del Rendimiento Algorítmico

La experimentación ha demostrado que el salto cualitativo entre los métodos constructivos (*Greedy*, Búsqueda Local) y los métodos poblacionales es determinante. Mientras que los primeros son adecuados para soluciones inmediatas, su incapacidad para escapar de mínimos locales los invalida en escenarios complejos como el Caso 3.

Entre los modelos evolutivos, se establece la siguiente jerarquía de eficacia:

- **CHC (Superioridad Absoluta):** Se consolida como la metaheurística más robusta y eficaz. Su diseño, carente de mutación convencional y fundamentado en la prevención de incesto y reinicios cataclísmicos, le otorga una capacidad de exploración superior. Su estabilidad estadística (CV promedio en torno al 2%, mínimo en los Casos 1 y 2) lo posiciona como la herramienta de elección para entornos donde la calidad final de la ruta es innegociable.
- **Multimodal (*Clearing*):** Actúa como un potente motor de diversificación. Aunque su calidad media es ligeramente inferior a la del CHC, su capacidad para sostener múltiples óptimos disjuntos simultáneamente (confirmada mediante el análisis visual de nichos) lo hace ideal para sistemas donde, además de eficiencia, se requiera flexibilidad operativa en la red.
- **AG Básico:** Identificado como un método de línea base. Aunque capaz de hallar soluciones de élite en ejecuciones aisladas, su dependencia de la semilla inicial y su sensibilidad paramétrica lo sitúan por debajo de los modelos especializados en cuanto a fiabilidad.

3.2 Justificación de la Métrica Estructural

Una de las lecciones fundamentales de esta práctica es la ineficacia de la distancia de Hamming clásica para problemas de rutas. La implementación de la **Distancia de Hamming orientada a arcos** ha sido el factor diferenciador que ha permitido tanto al CHC como al Multimodal gestionar la diversidad genética de manera coherente

con la función objetivo. La métrica por arcos no solo ha mejorado la convergencia, sino que ha proporcionado una interpretación matemática más fiel de la "distancia" entre soluciones topológicas.

3.3 Conclusión Final

El estudio de diseño paramétrico ha validado que los valores por defecto (umbrales $L/4$, radio $\sigma = 3$, elitismo estricto) no representan opciones arbitrarias, sino un punto de equilibrio entre la presión selectiva y el mantenimiento de la entropía poblacional.

En conclusión, la resolución del problema de optimización de rutas de bicicletas mediante algoritmos evolutivos avanzados no solo permite igualar o superar los estados del arte previos, sino que ofrece una Caja Blanca transparente que explica *cómo* y *por qué* se alcanzan dichas soluciones. El paradigma de *Clearing* y la estrategia de reinicio del CHC son, en última instancia, las mejores herramientas para navegar la rugosidad de los paisajes de búsqueda asimétricos, garantizando soluciones de alta eficiencia con una robustez estadística inalcanzable por métodos de trayectoria tradicionales.